

Coexist-Merge: 以当前模型为参照的迭代模型合并

Anonymous authors

Paper under double-blind review

ABSTRACT

模型合并所用的度量，应该描述各任务专家，还是实际接受更新的共享模型？我们从测量参照出发：参数在共享网络中的作用取决于当前输入、下游传播和师生分歧，而这些量还会随合并更新而变化。基于这一状态依赖，Coexist-Merge 在当前学生上收集输入二阶矩与归一化 KL 纠正二阶矩，以专家参数为锚点逐层求解，并在留出 KL 接受更新后重新测量。ViT-B/32 的配对诊断分别检验测量位置与统计重测；CLIP、T5 和 LLM 的已有结果进一步检验这一迭代框架的适用范围。

1 动机：合并度量应以哪个模型为参照？

模型合并需要协调多个任务专家在共享参数上的需求，而参数方向的重要性取决于测量它们的网络。Fisher merging 在各专家附近近似参数后验，RegMean 使用专家的层输入统计，MaTS 的 K-FAC 形式进一步结合输入与输出两侧信息 (Matena & Raffel, 2022; Jin et al., 2023; Tam et al., 2024)。这些统计适于描述各专家自身的行为。但合并后，参数将在同一个共享网络中工作：其上游输入、下游传播及尚未解决的预测分歧都可能与专家不同。因此，我们首先关注在各自专家上测得的度量，是否仍适合指导当前合并模型的更新。

在哪里测量：各任务专家，还是当前共享模型？ 两种选择都按任务分别统计 A_t, G_t ，区别是任务 t 的数据经过专家 θ_t ，还是经过当前合并模型 $\theta^{(r)}$ 。我们在 ViT-B/32 八任务上固定初始化、校准数据、ordinary-Fisher 定义和求解流程，仅切换这一个测量位置。共同初始状态下，四个预设非零全局步长上，学生统计提案的真实留出 KL 都更低 (图 1a)；例如步长 0.5 时为 0.16185，专家统计为 0.24632。首轮完整选步后的测试准确率分别为 87.1999% 与 85.1609%。优势在后续刷新之前已经出现，支持以待更新模型为测量参照。这是 ordinary-Fisher 下的位置对照；下一节再定义最终方法采用的归一化 KL 纠正统计。




图 1: 测量位置与接受更新后的重新测量。两组独立的 ViT-B/32 八任务、seed 0 对照。(a) ordinary-Fisher 首轮提案在同一初始化上的实际留出 KL；展示全部预设全局步长，尚未进行逐块选步。相同插值系数不代表相同参数位移。(b) 最终 KL-G 方法从 Average 出发的完整测试准确率；刷新与冻结共享第一轮状态，均继续求解与选步，虚线为单轮 CG400。两面板的统计定义和纵轴不同；不拼接为同一次运行。

为何迭代：继续修正，并更新修正所依赖的度量。 以当前状态为参照，并不意味着一次局部拟合足够。最终 KL-G 方法从 Average 出发，测试准确率由第一轮的 83.712% 提高到第四轮的 85.312%。冻结初始 A/G 后继续求解与迭步得到 84.519%，单次 CG400 得到 84.565% (图 1b)。这些对照分别支持后续更新的价值，以及在当前预算下重测统计的额外收益；更多 CG 步并没有替代外层适配。

重新测量的理由来自同一状态依赖：接受更新后，即使专家和图像固定，当前输入与师生纠正也会变化。Average 首轮前后，固定图像上的纠正梯度余弦中位数为 0.248。进一步固定同一个第一轮 checkpoint，分别用当前与初始统计构造并接受更新，独立诊断 KL 的降低量为 0.080560 与 0.044534。该干预把统计变化与更新效果联系起来。刷新收益仍依赖起点与阶段，RegMean 的刷新、冻结终态接近；完整对照与负结果见附录 A。

以上两个问题指向统一的设计：**在当前合并模型上测量各任务的输入与纠正需求，求解合并提案，并在接受后重新测量。**专家提供参数锚点及预测目标，学生提供这些目标在当前共享网络中的测量参照。下一节给出估计与求解过程；跨任务规模、模型设定及起点的适用性作为实验性质验证，而不预设任务或初始化的无条件独立性。

2 COEXIST-MERGE：测量、求解与重新测量

给定预训练基座 θ_0 、任务专家 $\theta_1, \dots, \theta_T$ ，以及各任务不重叠的无标签统计集 $\mathcal{C}_t$ 与留出集 $\mathcal{H}_t$ ，输出一个共享骨干。数据只提供任务归属，不提供类别标签或答案。以兼容合并结果初始化 $\theta^{(0)}$ ，默认使用 Iso-C 1.3 (Marczak et al., 2025)。分类头、嵌入等不合并部分按各设定保留。

2.1 在当前学生上估计两侧统计

对线性层 ℓ ，令输入为 $h^\ell \in \mathbb{R}^{d_{\text{in}}}$ 、输出为 $y^\ell \in \mathbb{R}^{d_{\text{out}}}$ 。采用样本按行的权重约定 $W^\ell \in \mathbb{R}^{d_{\text{in}} \times d_{\text{out}}}$ ；省略固定偏置、用列向量表示激活时， $y^\ell = (W^\ell)^\top h^\ell$ 。下文省略轮次下标，每轮均在当前 $\theta^{(r)}$ 上测量。任务 t 的输入侧为

$$A_t^\ell = \mathbb{E}_{x \sim \mathcal{C}_t} [h^\ell(x) h^\ell(x)^\top]. \quad (2.1)$$

它是按 token 或 patch 展平的未中心化二阶矩。

输出侧由专家提供教师分布 p ，当前学生提供 q 。对一个预测位置，定义逐类修正及卡方归一化

$$a_c = \frac{p_c}{q_c} - 1, \quad D = \chi^2(p||q) = \sum_c q_c a_c^2, \quad \hat{a}_c = \frac{a_c}{\sqrt{D + \varepsilon}}. \quad (2.2)$$

令 $s_c^\ell = \nabla_{y^\ell} \log q_c$ 、 $\bar{s}^\ell = \mathbb{E}_q[s_c^\ell]$ ，则该层聚合的纠正方向为

$$u_t^\ell(x) = \mathbb{E}_q[\hat{a}_c(s_c^\ell - \bar{s}^\ell)] = -\frac{\nabla_{y^\ell} D_{\text{KL}}(p||q)}{\sqrt{D + \varepsilon}}, \quad G_t^\ell = \mathbb{E}_x[u_t^\ell(x) u_t^\ell(x)^\top]. \quad (2.3)$$

这里梯度作用于层输出，与式 (2.1) 的层输入分开。实现时将每个样本的 KL 除以停止梯度的 $\sqrt{D + \varepsilon}$ ，再对样本求和反传，backward hook 即可收集 $-u$ ；符号不影响外积。CLIP 的 KL-G 收集每个 batch 只需一次反传，不需要逐类反传。序列模型按其预测位置与教师近似实现相应统计。

u 同时依赖当前残差与当前下游网络，并在师生预测一致时为零。 G 因而是纠正二阶矩，不是普通 Fisher 或真实 KL Hessian。卡方归一化移除额外的样本分歧幅度加权，保留纠正轴和层敏感度的差异。令 $J_\ell = \partial z / \partial y^\ell$ 、 $F(q) = \text{diag}(q) - qq^\top$ ，理想精确算术下有 $uu^\top \preceq J_\ell^\top F(q) J_\ell$ 。附录 B 给出该界、条件性优势和反例；它不保证所有任务的准确率都提高。

2.2 以专家参数为锚点逐层求解

先统一两侧统计的平均对角元，并仅对输出侧做由样本估计强度的 Ledoit–Wolf 收缩。对非零 $d \times d$ 矩阵 M ，处理为

$$\mathcal{S}_\lambda(M) = (1 - \lambda) \frac{M}{\text{tr}(M)/d} + \lambda I, \quad \mathcal{S}_\lambda(0) = 0. \quad (2.4)$$

算法 1: 外层重新测量与内层 CG 求解。**输入:** 专家 $\{\theta_t\}$; 无标签集合 $\{\mathcal{C}_t, \mathcal{H}_t\}$; 起点 $\theta^{(0)}$; 上限 $R \leq 4$ **输出:** 共享模型 $\hat{\theta}$

```

1  $\hat{\theta} \leftarrow \theta^{(0)}$ ; 准备固定教师预测
2 for  $r = 0, \dots, R - 1$  do
3   在当前模型上收集各任务、各层的  $A_t^\ell, G_t^\ell$ , 按式 (2.4) 处理
4   从当前权重出发, 以 CG100 求解式 (2.6), 得到各层候选  $X^\ell$ 
5   固定候选, 用  $\mathcal{L}_{\mathcal{H}}$  选全局尺度; CLIP 再细化各组尺度
6   按式 (2.7) 得到  $\theta^{(r+1)}$ ; 若留出 KL 严格更低则更新  $\hat{\theta}$ 
7   满足停止条件则退出; 否则在新状态上进入下一轮

```

输入取 $\lambda = 0$, 输出强度逐任务、逐层估计。为简洁起见, 以下求解式中的 A_t^ℓ, G_t^ℓ 均指处理后的矩阵。

当前输入与纠正轴给出候选 X 相对专家 W_t^ℓ 的平方响应差 $\mathbb{E}[(h^{\ell\top}(X - W_t^\ell)u_i^\ell)^2]$ 。采用 K-FAC 形式的因子化 (Martens & Grosse, 2015), 以 $G_t^\ell \otimes A_t^\ell$ 表示双侧权重, 构造逐层回归代理

$$\min_X \frac{1}{2} \sum_{t=1}^T \left\| (A_t^\ell)^{1/2} (X - W_t^\ell) (G_t^\ell)^{1/2} \right\|_F^2. \quad (2.5)$$

其正规方程沿用相同权重约定:

$$\sum_{t=1}^T A_t^\ell X G_t^\ell = \sum_{t=1}^T A_t^\ell W_t^\ell G_t^\ell. \quad (2.6)$$

我们以当前 $W^{\ell,(r)}$ 为初值, 用对角预条件 CG 至多求解 100 步, 无需显式构造完整 Kronecker 矩阵。某任务的 G 为零时不参与该层拟合; 整层没有有效信号时保留当前权重。

这一线性求解形式与 MaTS 相承 (Tam et al., 2024), 设计重点是用当前学生的纠正统计建立系数, 并在接受更新后重估。令 $G = I$ 可得到仅含输入权重的 RegMean 类回归形式, 但不能据此等同两者的完整实现。式 (2.5) 是结合专家锚点、因子化和统计处理构造的代理, 不是网络 KL 的精确二阶展开, 因此还需检验提案在完整网络上的实际效果。

2.3 用留出 KL 接受更新并迭代

将各层候选组成完整模型, 按

$$W^{\ell,(r+1)} = (1 - \omega_\ell) W^{\ell,(r)} + \omega_\ell X^\ell, \quad \omega_\ell \in \{0, \frac{1}{8}, \frac{1}{4}, \frac{1}{2}, 1\} \quad (2.7)$$

选择接受幅度。CLIP 先选全局尺度, 再按 13 组块细化, 各组内共享尺度; T5 与 LLM 仅选全局尺度。每次均评价完整模型, 目标为

$$\mathcal{L}_{\mathcal{H}}(\theta) = \frac{1}{T} \sum_{t=1}^T \frac{1}{|\mathcal{H}_t|} \sum_{x \in \mathcal{H}_t} D_{\text{KL}}(p_t(\cdot | x) \| q_{t,\theta}(\cdot | x)). \quad (2.8)$$

序列任务先按其有效预测位置聚合每条输入的 KL。零步长允许拒绝更新。接受后, 在新的 $\theta^{(r+1)}$ 上重算 A/G, 固定专家与统计输入。至多四轮, 所有尺度为零、相对更新低于阈值或预算耗尽时停止; 包括初始化在内, 返回留出 KL 最低的轮次, 同分取更早者。测试分数不参与这些选择。

3 效果与适用范围

主实验。 表 1 摘录已有正式结果。CLIP ViT-B/32 八任务上, 四个校准 seed 的均值为 87.06%。T5-base 的 85.64 包含由无标签留出 KL 选择的目标插值扩展 ($\alpha = 0.3$); T5-large 选择 $\alpha = 0$, 即原版方法。因此, 两种规模共同支持迭代框架的可用性, 但 base 的成绩不单独归因于原版统计与求解。

表 1: 主实验摘要。分数沿用各基准口径, 不跨行相减。T5 的 $\pm$ 沿用原记录的跨 seed 汇总; 移植 FeatCal 的 base 使用 5 seed, 本方法使用 3 seed。

设定	参照方法	参照分数	Coexist-Merge
CLIP ViT-B/32	ESM	84.19	87.06
T5-base	TA + FeatCal (移植)	84.84 ± 0.19	85.64 ± 0.04
T5-large	TA + FeatCal (移植)	89.06	88.99

跨任务规模与模型设定。 在独立的 CLIP 工作台实现中, 三个骨干与 8/14/20 任务构成的九格均较 Iso-C 起点提高 1.38–16.66 个百分点。该实现的 ViT-B/32 八任务结果为 86.60%, 不与正式实现的 87.06% 混为同一次运行。T5 使用教师答案上的 teacher-forced 分布, LLM 使用教师 top-128 logits; 两者保留“当前统计、逐层求解、留出选步、接受后重测”的共同流程, 具体教师近似和搜索粒度按设定适配。

表 2: LLM 的起点与后处理结果 (单 seed)。同一行比较同一模型及指标; 这是起点前后对照, 不是所有方法的排名表。

模型	起点	GSM8K		IFEval	
		起点	接受后	起点	接受后
Llama-3.2-3B	Iso-C 1.3	52.84	55.65	9.80	13.12
Llama-3.2-3B	TSV-M	54.13	55.04	18.30	15.53
Llama-3.2-3B	RegMean $\alpha=0.5$	53.53	52.39	11.46	13.12
Gemma-2-2B	Model Soup	35.25	48.07	18.11	26.06

表 2 同时保留收益与下降。Llama 的 RegMean 起点在 GSM8K 上下降, TSV-M 起点的 IFEval 也下降; 完整记录中 Llama 的三域宏平均最高仍是 TSV-M 起点自身。Gemma 的 Localize-and-Stitch 为 51.33, 高于所列后处理结果。因此, 我们主张的是同一迭代框架在多种设定中可用, 而不是所有任务均提升、所有基线均被超越, 或完全不需设定适配。

起点与组件性质。 初始化适配作为附加性质检验: ViT-B/32 的 Average 与 RegMean 诊断准确率差距由 22.36 缩到 0.15 个百分点, 但未拉平对照仍保留明显差距 (附录 A)。归一化的同机直接消融为 87.0451% 对 86.6652%, 其几何解释及优势条件见附录 B。这些结果分别检验适用范围与组件作用, 不替代图 1 对测量位置和重测价值的检验。

REFERENCES

- Xisen Jin, Xiang Ren, Daniel Preotiuc-Pietro, and Pengxiang Cheng. Dataless knowledge fusion by merging weights of language models. In *International Conference on Learning Representations*, 2023. URL <https://arxiv.org/abs/2212.09849>.
- Daniel Marczak, Simone Magistri, Sebastian Cygert, Bartłomiej Twardowski, Andrew D. Bagdanov, and Joost van de Weijer. No task left behind: Isotropic model merging with common and task-specific subspaces. In *Proceedings of the 42nd International Conference on Machine Learning*, 2025. URL <https://arxiv.org/abs/2502.04959>.
- James Martens and Roger Grosse. Optimizing neural networks with kronecker-factored approximate curvature. In *Proceedings of the 32nd International Conference on Machine Learning*, volume 37, pp. 2408–2417, 2015. URL <https://proceedings.mlr.press/v37/martens15.html>.
- Michael Matena and Colin Raffel. Merging models with fisher-weighted averaging. In *Advances in Neural Information Processing Systems*, 2022. URL <https://arxiv.org/abs/2111.09832>.
- XuanLong Nguyen, Martin J. Wainwright, and Michael I. Jordan. Estimating divergence functionals and the likelihood ratio by convex risk minimization. *IEEE Transactions on Information Theory*, 56(11):5847–5861, 2010. URL <https://arxiv.org/abs/0809.0853>.
- Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision. In *Proceedings of the 38th International Conference on Machine Learning*, 2021. URL <https://arxiv.org/abs/2103.00020>.
- Derek Tam, Mohit Bansal, and Colin Raffel. Merging by matching models in task parameter subspaces. *Transactions on Machine Learning Research*, 2024. URL <https://arxiv.org/abs/2312.04339>.

A 动机实验的协议与对照

共同设置与数据用途。 所有动机实验使用 CLIP ViT-B/32 (Radford et al., 2021)、八个固定任务专家 (Cars、DTD、EuroSAT、GTSRB、MNIST、RESISC45、SVHN、SUN397) 及 seed 0。每任务统计集包含 256 张图像，另外 256 张不重叠图像用于式 (2.8) 的选步与选轮；每轮 CG100，最多四轮。图 1a 使用 ordinary-Fisher，其余迭代与起点诊断使用原版归一化 KL-G。完整测试只用于报告，不参与更新选择。多起点研究在 validation 的前 256 张图像上诊断，并在其中 64 张记录 block 表征；刷新研究另用固定随机选取的 256 张 validation 图像诊断。因此，两组诊断指标仅在各自配对协议内比较。

专家与学生统计的位置对照。 图 1a 的两次运行使用相同 RTX 4080 SUPER、Iso-C 1.3 起点、资产指纹和配置摘要；初始 checkpoint 的 SHA-256 完全一致。两支均按其测量网络的预测分布逐类计算 ordinary-Fisher，仅切换前向输入和输出 Fisher 所属的网络。图中全局提案共享起点与预设步长，但提案范数不同；首轮尚不涉及后续统计刷新。原始 A/G 的固定随机投影显示初始学生/专家余弦均值约为 0.7825/0.4792，该差异本身不证明更新质量，故正文以真实 KL 为主证据。学生执行四轮、留出选择第四轮，测试为 87.2941%；专家执行三轮、选择第二轮，测试为 85.1807%，第三轮全部拒绝。逐轮测试是被动观测，没有改变选择规则。本次学生记录不同于历史 87.2704%，也不与最终 KL-G 的 87.06% 混用。该位置对照未拆分 A 与 G 各自的贡献；若将 KL-G 的学生直接替换成同一教师，残差会归零，因此不能把这种替换当作同定义的专家侧非零对照。

多起点适配及其边界。 表 3 保留全部四种起点。未拉平对照保持聚合任务增量的奇异值比例，逐原始二维矩阵匹配 Iso-C 的增量 Frobenius 范数；控制覆盖 49 个矩阵，包括拼接 Q/K/V，其余参数沿用 Iso-C。两者终态仍有 8.25 个百分点的测试差距，说明总增量能量不能独自解释可修复性。Average/RegMean 的参数距离采用逐层差异除以预训练层权重范数，再取中位数；其 2.53% 不能解释为全模型欧氏距离。

表 3: 完整四起点对照 (%)。诊断与完整测试属于不同分割；四组均由留出 KL 选中第四轮。

初始化	初始诊断	第四轮诊断	终态测试
Average	61.28	89.50	85.31
RegMean	83.64	89.65	85.55
Iso-C	87.74	92.92	87.06
未拉平 (范数匹配)	28.86	82.18	78.80

继续更新与重测统计分别起什么作用？ 对每种初始化先共享第一轮模型 $\theta^{(1)}$ ，再分为刷新和冻结两支。冻结分支固定初始 A/G 及收缩配置，仍然继续求解和选择步长；刷新分支在各自当前模型上重测。两支复用同一批图像。单轮 CG400 从原初始化出发，仅求解一次初始统计问题。表 4 显示，Average 第一轮之后的 1.6004 个百分点收益中，冻结流程也取得 0.8069 个百分点，刷新流程的额外收益为 0.7935 个百分点。

表 4: 完整测试准确率 (%)。最后一列为百分点差；单轮 CG400 不是等耗时或已收敛对照。

初始化	第一轮	四轮冻结	四轮刷新	单轮 CG400	刷新 - 冻结
Average	83.712	84.519	85.312	84.565	0.794
RegMean	85.385	85.546	85.549	85.574	0.003
Iso-C	86.972	86.941	87.056	86.624	0.115

统计、方向与接受规则的作用需要区分。 正文同状态干预保持待更新 checkpoint 一致，但其终态收益包含重测、收缩、有限 CG 和选步的共同作用。将 Average 的原始新旧提案匹配中心化 logit RMS 后， $\theta^{(1)}$ 上旧/新方向分别降低独立诊断 KL 0.003379/0.002503， $\theta^{(2)}$ 上则为 0.000481/0.002089。因此，当前统计的接受终态更好，不自动意味着原始方向在每个等幅比较中都更好。现有冻结对照也没有单独检验第二轮之后每一轮刷新的必要性。

周围网络改变，本块也可能需要适配。 固定目标 block 的全部权重为初始值，其余网络换成第一轮状态。所有比较从同一个混合模型出发，仅允许目标 block 的线性层更新；分别使

用初始统计和在混合模型上重测的统计。Average 的 block 11 自身权重未变，输入与纠正梯度余弦却降至 0.8449、0.4915，使用当前统计也获得更大的独立诊断 KL 降低量。图 2 同时保留 block 0 的负结果，支持有条件的网络状态适配。




图 2: 固定本块权重的跨 block 干预。Average, seed 0。每个 block 的两根柱共享同一混合起点，纵轴为接受更新后的独立诊断 KL 降低量，越大越好；不同 block 的起点各不相同。三个 block 为预先选定的 0、5、11。

归一化的直接消融。 另一组同机 RTX 4090、seed 0 的配对记录中，归一化与未归一化版本的资产指纹、配置摘要及初始化相同，均刷新四轮并选中第 4 轮；平均测试准确率分别为 87.0451%、86.6652%，最终留出 KL 为 0.155523、0.169934。该消融支持组件有效，但不单独识别卡方相对其他归一化的优势。它与多起点研究的 87.0558% 属于不同运行记录，不拼接为同一轨迹。上述结果均未提供跨 seed 显著性结论。

B 卡方归一化的依据与优势边界

以下固定一个样本, 设教师 p 为概率分布、学生 $q_c > 0$, $e = p - q$, $\mathbf{1}^\top e = 0$, $D = \sum_c e_c^2 / q_c$. $F = \text{diag}(q) - qq^\top$, J 为当前学生的 logit Jacobian。所有界均作用于矩阵尺度统一和收缩之前的纠正外积。

B.1 学生 FISHER 几何下的精确尺度

命题 B.1 (锐利的 Fisher 相对预算). 对 $e \neq 0$,

$$D = \sup_{\text{Var}_q(f) > 0} \frac{(\mathbb{E}_p f - \mathbb{E}_q f)^2}{\text{Var}_q(f)} = e^\top F^\dagger e, \quad ee^\top \preceq dF \iff d \geq D. \quad (\text{B.1})$$

因此, 对 $u = J^\top e / \sqrt{D + \varepsilon}$, $\varepsilon \geq 0$, 有

$$uu^\top \preceq \frac{D}{D + \varepsilon} J^\top F J \preceq J^\top F J. \quad (\text{B.2})$$

证明. 令 $a_c = p_c / q_c - 1$, 则 $\mathbb{E}_q a = 0$, $\mathbb{E}_q a^2 = D$. 对任意 f , $\mathbb{E}_p f - \mathbb{E}_q f = \mathbb{E}_q[a(f - \mathbb{E}_q f)]$. Cauchy-Schwarz 给出平方差至多为 $D \text{Var}_q(f)$, 取 $f = a$ 达到等号。又有 $F \text{diag}(q)^{-1} e = e$, 且 $\ker F = \text{span}(\mathbf{1})$. 任一解与 $F^\dagger e$ 仅差常数向量, 左乘 $e^\top$ 即得 $e^\top F^\dagger e = D$. 矩阵不等式等价于对所有 f 都有 $(f^\top e)^2 \leq df^\top F f$, 其最小 d 由刚才的上确界确定。最后除以 $D + \varepsilon$ 并作 $J^\top(\cdot)J$ 合同变换即可。□

这一结论是经典散度变分框架 (Nguyen et al., 2010) 在当前纠正信号上的具体化。它说明根号卡方是保留 logit 残差方向并满足单位学生 Fisher 预算的最小分母; 原始外积满足同一预算当且仅当 $D \leq 1$, 这里的 1 是预算尺度, 非精度阈值。若换成其他分母 $\sqrt{s}$, 同一个全方向保证要求 $s \geq D$ 。例如 $p = (1, 0)$, $q = (\delta, 1 - \delta)$ 时, $D / (2D_{\text{KL}}(p \| q)) \rightarrow \infty$, 故根号 KL 没有同一全局保证。这不排除它在其他目标上更有效。

B.2 整体尺度统一后, 改变的是方向权重

将一个图像全部 token 的归一化外积相加, 记为 Z_i 。令 $s_i = D_i + \varepsilon$, $a_i = \text{tr} Z_i$, $P_i = Z_i / a_i$, 忽略 $a_i = 0$ 的项, 且假设总迹非零。归一化与未归一化矩阵的单位迹形式分别为

$$N = \sum_i b_i P_i, \quad R = \sum_i \frac{b_i s_i}{\bar{s}} P_i, \quad b_i = \frac{a_i}{\sum_j a_j}, \quad \bar{s} = \sum_i b_i s_i. \quad (\text{B.3})$$

直接展开可得

$$R - N = \frac{\sum_i b_i (s_i - \bar{s})(P_i - N)}{\bar{s}} = \frac{\text{Cov}_b(s, P)}{\bar{s}}. \quad (\text{B.4})$$

实际的平均对角线统一尺度仅再乘输出维度。因此, 归一化的作用不止于改变整体梯度大小, 而是移除额外的分歧幅度加权; 归一化后的层能量 a_i 仍有差异。若所有 s_i 或所有 P_i 相同, 两种形状一致。自动收缩也会随统计变化, 故式 (B.4) 只刻画收缩前的直接作用。

B.3 何时能得到更好的合并解?

几何预算本身不保证更高准确率。下面给出一个保留式 (2.5) 结构的可解析条件: 固定两个专家 $w_1 = e_1 = (1, 0)^\top$, $w_2 = 0$ 、输入度量均为 1, 第二任务输出度量为 $I/2$ 。第一任务的参考需求为保留 e_1 方向; 其估计度量中, 非目标方向 e_2 在归一化后占比为 $0 < \rho < 1$ 。设两类方向的分歧平方幅度比为

$$k = \frac{s_{\text{nuisance}}}{s_{\text{useful}}} > 0, \quad \tau = \frac{\rho k}{1 - \rho + \rho k}. \quad (\text{B.5})$$

则第一任务单位迹度量分别为 $\text{diag}(1 - \rho, \rho)$ 与 $\text{diag}(1 - \tau, \tau)$ 。

命题 B.2 (两专家二次合并的风险边界). 定义

$$L_t(w) = \frac{1}{2}(w - e_1)^\top \text{diag}(1 - t, t)(w - e_1) + \frac{1}{2}w^\top (I/2)w, \quad w(t) = \arg \min_w L_t(w). \quad (\text{B.6})$$

以预先指定的无污染目标 L_0 为参照, 精确求解且不作输出收缩时,

$$L_0(w(\rho)) < L_0(w(\tau)) \iff k > 1. \quad (\text{B.7})$$

证明. Hessian 为 $\text{diag}(3/2-t, 1/2+t) \succ 0$, 故 $w(t) = ((1-t)/(3/2-t), 0)^\top$, $w(0) = (2/3, 0)^\top$. 代入同一参考目标, 得到超额风险

$$\mathcal{E}(t) = L_0(w(t)) - L_0(w(0)) = \frac{3}{4} \left(\frac{1-t}{3/2-t} - \frac{2}{3} \right)^2 = \frac{t^2}{3(3-2t)^2}. \quad (\text{B.8})$$

它在 $(0, 1)$ 上严格递增, 而 $\tau - \rho = \rho(1 - \rho)(k - 1)/(1 - \rho + \rho k)$, 因此结论成立。 $\square$

该构造说明, 当非目标方向同时具有更大的分歧幅度时, 原始外积会进一步提高其权重, 而归一化可以降低合并风险。 $k = 1$ 持平, $k < 1$ 时同一目标下未归一化严格更好。归一化也有非零污染误差 $\mathcal{E}(\rho)$, 因此参照目标并未事后定义为归一化解。命题是二次代理中的条件性结果, 实际网络中“高分歧是否意味着低价值”需要独立干预检验。

实现与适用范围。 使用 $\varepsilon = 10^{-8}$ 并 detach 分母; 实际 $p \rightarrow q$ 时纠正趋零。数学证明要求正概率与精确算术, float32 下溢或 tiny clamp 触发时不直接沿用精确 Fisher 恒等式。学生自信但错误也可能使归一化压低重要纠正: 当 $p = (1, 0), q = (\delta, 1 - \delta)$, KL 发散而 $\|(p - q)/\sqrt{D + \varepsilon}\|_2 \sim \sqrt{2\delta} \rightarrow 0$ 。此外, 自动收缩、有限 CG、非线性传播和选步都会影响最终结果; 本附录不提供完整网络准确率 of 的普遍支配保证。