

INK-Merge: 基于当前修正几何的迭代模型合并

Anonymous authors

Paper under double-blind review

ABSTRACT

不同合并起点的功能差距，可以在相同的后续修正流程中显著缩小。这促使我们关注当前合并模型仍然缺失的任务功能。我们进一步观察到，一次更新后仍有继续修正的空间，而更新本身会改变下一步依赖的输入与纠正统计。基于这一状态依赖，INK-Merge 在当前模型上收集输入激活和归一化教师-学生 KL 纠正信号，以专家参数为锚点求解逐层加权回归，并在接受更新后重新测量。ViT-B/32 八任务的配对诊断支持这一迭代适配过程；卡方归一化的几何依据与优势条件在附录中给出。

1 从合并起点到当前模型的修正需求

模型合并将同一预训练模型独立微调得到的专家整合为单一模型。权重平均与任务算术提供了直接的参数组合方式 (Wortsman et al., 2022; Ilharco et al., 2023); Fisher merging, RegMean 及 MaTS 进一步利用任务相关的敏感度或输入统计，区分不同参数方向的作用 (Matena & Raffel, 2022; Jin et al., 2023; Tam et al., 2024)。在已有合并结果上，我们关注一个后续问题：如何识别当前模型仍然缺失的任务功能，并据此继续修正？

一个促使我们关注这一问题的现象是：起点的功能差距，可以在相同的后续修正流程中显著缩小。在 CLIP ViT-B/32 八任务设置中，固定专家、无标签校准图像和修正规则，Average 与 RegMean 在同一独立诊断集上的准确率差距由 22.36 缩小到四轮后的 0.15 个百分点 (图 1a)。这表明，常用合并起点留下的差异仍有相当部分可以被后续过程修复。我们因而将注意力放到修正过程中模型还需要什么：合并起点提供初始能力，后续更新继续协调尚未满足的任务需求。以下为 seed 0 的配对机制诊断，每轮 CG100、最多四轮；完整协议见附录 A。

进一步观察修正过程，Average 的完整测试准确率从第一轮 83.712% 提高到第四轮的 85.312%，说明一次接受更新后仍有继续修正的空间。但如何进行下一次修正同样重要：冻




图 1: 从起点适配到当前状态下的继续修正。ViT-B/32, 八任务, seed 0。 (a) 三种常用起点在同一独立诊断集上的准确率。 (b) Average 的完整测试准确率: 刷新与冻结共享第一轮模型, 均继续求解和选择步长; 虚线为单轮 CG400。 (c) 相邻学生状态的实际求解度量 $\bar{A} \otimes \bar{G}$ 的余弦距离, 取层/任务中位数, 纵轴为对数尺度。 (a) 与 (b) 使用不同数据分割, 数值不跨面板相减; (c) 比较同一批校准图像上的统计。完整对照见附录 A。

结初始统计后继续求解和选步，四轮得到 84.519%；仅将初次求解延长到 CG400，得到 84.565% (图 1b)。在这些预算下，继续求解初始统计问题没有复现刷新流程的全部收益。这提示我们关注的不仅是求解走了多少步，还包括下一步依据哪个模型状态来测量。

理解这一差异，需要考虑更新带来的网络状态变化。即使专家与图像固定，上游激活、学生预测和下游传播仍会变化。Average 首轮前后，固定诊断图像上的纠正梯度余弦中位数仅为 0.248；实际求解度量也发生明显变化 (图 1c)。单看变化尚不能判断它是否影响更新，因此我们进一步固定同一个第一轮 checkpoint，分别用当前与初始统计构造并接受修正：独立诊断 KL 的降低量为 0.080560 与 0.044534。这一干预把统计的状态依赖与接受更新的实际效果联系起来，支持下一轮重新测量当前模型。

由此得到我们的设计原则：**依据当前模型的输入与师生分歧构造修正，接受后再适配新的网络状态**。对一层而言，输入决定参数改动作用于哪些特征，师生残差经当前下游网络反传后，指出仍有分歧的输出轴。我们分别用二阶矩 A 和 G 表达这两方面，以专家参数为锚点构造逐层合并问题，再用真实留出 KL 判断是否接受提案。这也明确了与专家统计的区别：专家处的测量服务于保留专家自身的行为，而我们希望衡量这些参数目标在当前合并网络中的作用。因此，测量位置与接受后的重新测量是同一原则的两个环节。

上述观察支持的是有条件的适配：RegMean 上刷新与冻结的终态表现接近，后期统计也逐渐稳定；起点适配同样不意味着任意初始化都收敛到同一结果。附录 A 保留这些边界，以及同状态干预的等幅对照和跨 block 干预，避免把接受终态的优势解释为所有原始更新方向都更优。

2 INK-MERGE：测量、求解与重新适配

上一节的观察对应三个步骤：在当前模型上测量任务修正需求，以这些统计求解合并提案，再在接受更新后重新测量。下面给出各步骤的具体形式。

2.1 在当前模型上估计输入与纠正统计

给定 T 个固定专家 $\{\theta_t\}_{t=1}^T$ ，以兼容的合并结果初始化共享编码器 $\theta^{(0)}$ ，任务头固定。记专家与当前学生的任务分布为 $p_t(c|x)$ 、 $q_t, \theta(c|x)$ 。每任务使用不重叠的无标签统计集 $\mathcal{C}_t$ 和留出集 $\mathcal{H}_t$ ；前者收集统计，后者通过任务等权的行为目标

$$\mathcal{L}_{\mathcal{H}}(\theta) = \frac{1}{T} \sum_{t=1}^T \frac{1}{|\mathcal{H}_t|} \sum_{x \in \mathcal{H}_t} D_{\text{KL}}(p_t(\cdot|x) \| q_{t,\theta}(\cdot|x)) \quad (2.1)$$

选择步长与输出轮次。标签不参与选择；默认使用 Iso-C (Marczak et al., 2025) 初始化，其他起点沿用相同修正规则。

对一个样本省略任务与轮次下标。令 $a_{\ell k}, h_{\ell k}$ 为线性层 ℓ 在 token k 的输入与输出， z 为学生 logits， $J_{\ell k} = \partial z / \partial h_{\ell k}$ 。教师固定时，

$$g_{\ell k} = -\nabla_{h_{\ell k}} D_{\text{KL}}(p \| q) = J_{\ell k}^\top (p - q), \quad \delta \ell_{\text{KL}} \approx -\sum_k g_{\ell k}^\top \delta W_{\ell} a_{\ell k}. \quad (2.2)$$

右式是仅扰动该层权重时的一阶关系：当前输入、下游传播和师生残差共同决定局部功能影响。它具体说明了上一节中统计随状态变化的原因；当师生预测匹配时，纠正信号为零。下文省略 token 下标，并以

$$D = \chi^2(p \| q) = \sum_c \frac{(p_c - q_c)^2}{q_c}, \quad u_{\ell} = \frac{g_{\ell}}{\sqrt{D + \varepsilon}}, \quad \tilde{\ell} = \frac{D_{\text{KL}}(p \| q)}{\text{stopgrad}(\sqrt{D + \varepsilon})} \quad (2.3)$$

收集归一化纠正。反传 $\tilde{\ell}$ 并停止分母梯度得到 $-u_{\ell}$ ，符号不影响外积。分歧幅度不必等于一个纠正轴应获得的合并权重。卡方归一化移除额外的分歧幅度加权，同时保留纠正轴及层敏感度差异。在正概率和精确算术下， $u_{\ell} u_{\ell}^\top \preceq J_{\ell}^\top F(q) J_{\ell}$ ，其中 $F(q) = \text{diag}(q) - qq^\top$ 。相对未归一化的配对消融提高 0.3799 个准确率百分点；几何证明、优势条件与反例见附录 B。

对任务 t 的当前模型 $\theta^{(r)}$ ，在 $\mathcal{C}_t$ 上估计

$$A_t^{\ell, (r)} = \mathbb{E}[a_{\ell} a_{\ell}^\top], \quad G_t^{\ell, (r)} = \mathbb{E}[u_{\ell} u_{\ell}^\top]. \quad (2.4)$$

期望覆盖图像和所收集的 token。 A 是当前输入的未中心化二阶矩， G 是当前 KL 纠正的未中心化二阶矩。 G 并非普通 Fisher 或真实 KL Hessian；它保留纠正轴的相对权重，不保留纠正方向的正负号。

算法 1: INK-Merge: 在当前模型上测量、求解, 并在接受后重新适配。

输入: 专家 $\{\theta_t\}$; 固定无标签集合 $\{\mathcal{C}_t, \mathcal{H}_t\}$; 初始化 $\theta^{(0)}$; 轮数 R

输出: 合并模型 $\hat{\theta}$

```

1 缓存专家在  $\mathcal{C}_t \cup \mathcal{H}_t$  上的预测;  $\mathcal{Q} \leftarrow \{\theta^{(0)}\}$ 
2 for  $r = 0, \dots, R-1$  do
3   在当前  $\theta^{(r)}$  上收集 A/G, 并按式 (2.5) 处理尺度与收缩
4   从当前权重出发, 以 CG 求解式 (2.7), 得到候选  $\theta^*$ 
5   固定本轮候选, 以留出 KL 选择全局及各 block 步长
6   按式 (2.8) 接受  $\theta^{(r+1)}$ , 加入  $\mathcal{Q}$ ; 满足停止条件则退出
7  $\hat{\theta} \leftarrow \arg \min_{\theta \in \mathcal{Q}} \mathcal{L}_{\mathcal{H}}(\theta)$ 

```

2.2 以专家为锚点构造加权回归

设 W_t^ℓ 为专家权重、 U 为候选权重。我们在当前学生输入上比较二者的线性响应, 再沿当前纠正轴投影, 得到平方差 $\mathbb{E}[(u^\top(U - W_t^\ell)a)^2]$ 。借鉴 K-FAC 的因子化形式 (Martens & Grosse, 2015), 以 $A \otimes G$ 近似联合二阶矩 $\mathbb{E}[(aa^\top) \otimes (uu^\top)]$, 便可用两个小矩阵衡量输入与输出方向。

为统一矩阵尺度并稳定求解, 对非零 $d \times d$ 矩阵 M 使用

$$S_\lambda(M) = (1 - \lambda) \frac{M}{\text{tr}(M)/d} + \lambda I, \quad S_\lambda(0) = 0, \quad (2.5)$$

得到实际使用的 $\bar{A}, \bar{G}$ 。本文诊断中输入收缩为 0, 输出收缩由样本统计自动估计。随后近似求解

$$U^{\ell,*} \approx \arg \min_U \frac{1}{2} \sum_t \left\| (\bar{G}_t^{\ell,(r)})^{1/2} (U - W_t^\ell) (\bar{A}_t^{\ell,(r)})^{1/2} \right\|_F^2. \quad (2.6)$$

专家锚点确定参数目标, 学生统计决定不同偏离方向的权重。这一回归是我们构造的局部代理: 式 (2.2) 解释统计的来源, 却不能严格推出式 (2.6) 是网络 KL 的二阶展开。外积、因子化以及专家到学生的有限位移都引入了近似, 因此候选仍需通过真实留出 KL 检验。

正规方程为

$$\sum_t \bar{G}_t^{\ell,(r)} U^{\ell,*} \bar{A}_t^{\ell,(r)} = \sum_t \bar{G}_t^{\ell,(r)} W_t^\ell \bar{A}_t^{\ell,(r)}. \quad (2.7)$$

沿用 MaTS 的线性系统求解方式 (Tam et al., 2024), 我们以当前权重为初值, 使用对角预条件 CG, 无需显式构造完整 Kronecker 矩阵。没有有效纠正信号的层保留当前权重。合并问题的系数来自当前师生纠正统计, 并在接受更新后重新估计。

2.3 接受更新后重新估计

将各层候选组合为 θ^* , 记 block 增量 $D_b^{(r)} = W_b^* - W_b^{(r)}$ 。先选择全局步长, 再依次细化各 block 步长:

$$W_b^{(r+1)} = W_b^{(r)} + \omega_b^{(r)} D_b^{(r)}, \quad \omega_b^{(r)} \in \Omega = \{0, 0.125, 0.25, 0.5, 1\}. \quad (2.8)$$

每次用完整模型的 $\mathcal{L}_{\mathcal{H}}$ 评价, 0 允许拒绝更新。接受后, a, q, J 均可能改变, 故下一轮在 $\theta^{(r+1)}$ 上重算 A/G; 专家与统计图像保持固定。外层迭代更新测量参照, 内层 CG 求解本轮固定的代理问题。所有 block 拒绝、相对更新低于阈值或达到预算时停止, 返回留出 KL 最低的状态。

REFERENCES

- Gabriel Ilharco, Marco Tulio Ribeiro, Mitchell Wortsman, Suchin Gururangan, Ludwig Schmidt, Hannaneh Hajishirzi, and Ali Farhadi. Editing models with task arithmetic. In *International Conference on Learning Representations*, 2023. URL <https://arxiv.org/abs/2212.04089>.
- Xisen Jin, Xiang Ren, Daniel Preotiu-Pietro, and Pengxiang Cheng. Dataless knowledge fusion by merging weights of language models. In *International Conference on Learning Representations*, 2023. URL <https://arxiv.org/abs/2212.09849>.
- Daniel Marczak, Simone Magistri, Sebastian Cygert, Bartłomiej Twardowski, Andrew D. Bagdanov, and Joost van de Weijer. No task left behind: Isotropic model merging with common and task-specific subspaces. In *Proceedings of the 42nd International Conference on Machine Learning*, 2025. URL <https://arxiv.org/abs/2502.04959>.
- James Martens and Roger Grosse. Optimizing neural networks with kronecker-factored approximate curvature. In *Proceedings of the 32nd International Conference on Machine Learning*, volume 37, pp. 2408–2417, 2015. URL <https://proceedings.mlr.press/v37/martens15.html>.
- Michael Matena and Colin Raffel. Merging models with fisher-weighted averaging. In *Advances in Neural Information Processing Systems*, 2022. URL <https://arxiv.org/abs/2111.09832>.
- XuanLong Nguyen, Martin J. Wainwright, and Michael I. Jordan. Estimating divergence functionals and the likelihood ratio by convex risk minimization. *IEEE Transactions on Information Theory*, 56(11):5847–5861, 2010. URL <https://arxiv.org/abs/0809.0853>.
- Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision. In *Proceedings of the 38th International Conference on Machine Learning*, 2021. URL <https://arxiv.org/abs/2103.00020>.
- Derek Tam, Mohit Bansal, and Colin Raffel. Merging by matching models in task parameter subspaces. *Transactions on Machine Learning Research*, 2024. URL <https://arxiv.org/abs/2312.04339>.
- Mitchell Wortsman, Gabriel Ilharco, Samir Yitzhak Gadre, Rebecca Roelofs, Raphael Gontijo-Lopes, Ari S. Morcos, Hongseok Namkoong, Ali Farhadi, Yair Carmon, Simon Kornblith, and Ludwig Schmidt. Model soups: Averaging weights of multiple fine-tuned models improves accuracy without increasing inference time. In *Proceedings of the 39th International Conference on Machine Learning*, 2022. URL <https://arxiv.org/abs/2203.05482>.

A 动机实验的协议与对照

共同设置与数据用途。 所有动机实验使用 CLIP ViT-B/32 (Radford et al., 2021)、八个固定任务专家 (Cars、DTD、EuroSAT、GTSRB、MNIST、RESISC45、SVHN、SUN397) 及 seed 0。每任务统计集包含 256 张图像，另外 256 张不重叠图像用于式 (2.1) 的选步与选轮；每轮 CG100，最多四轮，全部使用原版归一化 KL-G。完整测试只用于报告，不参与更新选择。多起点研究在 validation 的前 256 张图像上诊断，并在其中 64 张记录 block 表征；刷新研究另用固定随机选取的 256 张 validation 图像诊断。因此，两组诊断指标仅在各自配对协议内比较。

多起点适配及其边界。 表 1 保留全部四种起点。未拉平对照保持聚合任务增量的奇异值比例，逐原始二维矩阵匹配 Iso-C 的增量 Frobenius 范数；控制覆盖 49 个矩阵，包括拼接 Q/K/V，其余参数沿用 Iso-C。两者终态仍有 8.25 个百分点的测试差距，说明总增量能量不能独自解释可修复性。Average/RegMean 的参数距离采用逐层差异除以预训练层权重范数，再取中位数；其 2.53% 不能解释为全模型欧氏距离。

表 1: 完整四起点对照 (%)。诊断与完整测试属于不同分割；四组均由留出 KL 选中第四轮。

	初始化	初始诊断	第四轮诊断	终态测试
Average		61.28	89.50	85.31
RegMean		83.64	89.65	85.55
Iso-C		87.74	92.92	87.06
未拉平 (范数匹配)		28.86	82.18	78.80

继续更新与重测统计分别起什么作用？ 对每种初始化先共享第一轮模型 $\theta^{(1)}$ ，再分为刷新和冻结两支。冻结分支固定初始 A/G 及收缩配置，仍然继续求解和选择步长；刷新分支在各自当前模型上重测。两支复用同一批图像。单轮 CG400 从原初始化出发，仅求解一次初始统计问题。表 2 显示，Average 第一轮之后的 1.6004 个百分点收益中，冻结流程也取得 0.8069 个百分点，刷新流程的额外收益为 0.7935 个百分点。

表 2: 完整测试准确率 (%)。最后一列为百分点差；单轮 CG400 不是等耗时或已收敛对照。

	初始化	第一轮	四轮冻结	四轮刷新	单轮 CG400	刷新 - 冻结
Average		83.712	84.519	85.312	84.565	0.794
RegMean		85.385	85.546	85.549	85.574	0.003
Iso-C		86.972	86.941	87.056	86.624	0.115

统计、方向与接受规则的作用需要区分。 正文同状态干预保持待更新 checkpoint 一致，但其终态收益包含重测、收缩、有限 CG 和选步的共同作用。将 Average 的原始新旧提案匹配中心化 logit RMS 后， $\theta^{(1)}$ 上旧/新方向分别降低独立诊断 KL 0.003379/0.002503， $\theta^{(2)}$ 上则为 0.000481/0.002089。因此，当前统计的接受终态更好，不自动意味着原始方向在每个等幅比较中都更好。现有冻结对照也没有单独检验第二轮之后每一轮刷新的必要性。

周围网络改变，本块也可能需要适配。 固定目标 block 的全部权重为初始值，其余网络换成第一轮状态。所有比较从同一个混合模型出发，仅允许目标 block 的线性层更新；分别使用初始统计和在混合模型上重测的统计。Average 的 block 11 自身权重未变，输入与纠正梯度余弦却降至 0.8449、0.4915，使用当前统计也获得更大的独立诊断 KL 降低量。图 2 同时保留 block 0 的负结果，支持有条件的网络状态适配。

归一化的直接消融。 另一组同机 RTX 4090、seed 0 的配对记录中，归一化与未归一化版本的资产指纹、配置摘要及初始化相同，均刷新四轮并选中第 4 轮；平均测试准确率分别为 87.0451%、86.6652%，最终留出 KL 为 0.155523、0.169934。该消融支持组件有效，但不单独识别卡方相对其他归一化的优势。它与多起点研究的 87.0558% 属于不同运行记录，不拼接为同一轨迹。上述结果均未提供跨 seed 显著性结论。




图 2: 固定本块权重的跨 block 干预。Average, seed 0。每个 block 的两根柱共享同一混合起点, 纵轴为接受更新后的独立诊断 KL 降低量, 越大越好; 不同 block 的起点各不相同。三个 block 为预先选定的 0、5、11。

B 卡方归一化的依据与优势边界

以下固定一个样本, 设教师 p 为概率分布、学生 $q_c > 0$, $e = p - q$, $\mathbf{1}^\top e = 0$, $D = \sum_c e_c^2 / q_c$ 。 $F = \text{diag}(q) - qq^\top$, J 为当前学生的 logit Jacobian。所有界均作用于矩阵尺度统一和收缩之前的纠正外积。

B.1 学生 FISHER 几何下的精确尺度

命题 B.1 (锐利的 Fisher 相对预算)。对 $e \neq 0$,

$$D = \sup_{\text{Var}_q(f) > 0} \frac{(\mathbb{E}_p f - \mathbb{E}_q f)^2}{\text{Var}_q(f)} = e^\top F^\dagger e, \quad ee^\top \preceq dF \iff d \geq D. \quad (\text{B.1})$$

因此, 对 $u = J^\top e / \sqrt{D + \varepsilon}$, $\varepsilon \geq 0$, 有

$$uu^\top \preceq \frac{D}{D + \varepsilon} J^\top F J \preceq J^\top F J. \quad (\text{B.2})$$

证明. 令 $a_c = p_c / q_c - 1$, 则 $\mathbb{E}_q a = 0$, $\mathbb{E}_q a^2 = D$ 。对任意 f , $\mathbb{E}_p f - \mathbb{E}_q f = \mathbb{E}_q[a(f - \mathbb{E}_q f)]$ 。Cauchy-Schwarz 给出平方差至多为 $D \text{Var}_q(f)$, 取 $f = a$ 达到等号。又有 $F \text{diag}(q)^{-1} e = e$, 且 $\ker F = \text{span}(\mathbf{1})$ 。任一解与 $F^\dagger e$ 仅差常数向量, 左乘 $e^\top$ 即得 $e^\top F^\dagger e = D$ 。矩阵不等式等价于对所有 f 都有 $(f^\top e)^2 \leq d f^\top F f$, 其最小 d 由刚才的上确界确定。最后除以 $D + \varepsilon$ 并作 $J^\top(\cdot)J$ 合同变换即可。 $\square$

这一结论是经典散度变分框架 (Nguyen et al., 2010) 在当前纠正信号上的具体化。它说明根号卡方是保留 logit 残差方向并满足单位学生 Fisher 预算的最小分母; 原始外积满足同一预算当且仅当 $D \leq 1$, 这里的 1 是预算尺度, 非精度阈值。若换成其他分母 $\sqrt{s}$, 同一个全方向保证要求 $s \geq D$ 。例如 $p = (1, 0)$, $q = (\delta, 1 - \delta)$ 时, $D / (2D_{\text{KL}}(p \| q)) \rightarrow \infty$, 故根号 KL 没有同一全局保证。这不排除它在其他目标上更有效。

B.2 整体尺度统一后, 改变的是方向权重

将一个图像全部 token 的归一化外积相加, 记为 Z_i 。令 $s_i = D_i + \varepsilon$, $a_i = \text{tr} Z_i$, $P_i = Z_i / a_i$, 忽略 $a_i = 0$ 的项, 且假设总迹非零。归一化与未归一化矩阵的单位迹形式分别为

$$N = \sum_i b_i P_i, \quad R = \sum_i \frac{b_i s_i}{\bar{s}} P_i, \quad b_i = \frac{a_i}{\sum_j a_j}, \quad \bar{s} = \sum_i b_i s_i. \quad (\text{B.3})$$

直接展开可得

$$R - N = \frac{\sum_i b_i (s_i - \bar{s})(P_i - N)}{\bar{s}} = \frac{\text{Cov}_b(s, P)}{\bar{s}}. \quad (\text{B.4})$$

实际的平均对角线统一尺度仅再乘输出维度。因此，归一化的作用不止于改变整体梯度大小，而是移除额外的分歧幅度加权；归一化后的层能量 a_i 仍有差异。若所有 s_i 或所有 P_i 相同，两种形状一致。自动收缩也会随统计变化，故式 (B.4) 只刻画收缩前的直接作用。

B.3 何时能得到更好的合并解？

几何预算本身不保证更高准确率。下面给出一个保留式 (2.6) 结构的可解析条件：固定两个专家 $w_1 = e_1 = (1, 0)^\top, w_2 = 0$ 、输入度量均为 1，第二任务输出度量为 $I/2$ 。第一任务的参考需求为保留 e_1 方向；其估计度量中，非目标方向 e_2 在归一化后占比为 $0 < \rho < 1$ 。设两类方向的分歧平方幅度比为

$$k = \frac{s_{\text{nuisance}}}{s_{\text{useful}}} > 0, \quad \tau = \frac{\rho k}{1 - \rho + \rho k}. \quad (\text{B.5})$$

则第一任务单位迹度量分别为 $\text{diag}(1 - \rho, \rho)$ 与 $\text{diag}(1 - \tau, \tau)$ 。

命题 B.2 (两专家二次合并的风险边界). 定义

$$L_t(w) = \frac{1}{2}(w - e_1)^\top \text{diag}(1 - t, t)(w - e_1) + \frac{1}{2}w^\top (I/2)w, \quad w(t) = \arg \min_w L_t(w). \quad (\text{B.6})$$

以预先指定的无污染目标 L_0 为参照，精确求解且不作输出收缩时，

$$L_0(w(\rho)) < L_0(w(\tau)) \iff k > 1. \quad (\text{B.7})$$

证明. Hessian 为 $\text{diag}(3/2 - t, 1/2 + t) \succ 0$, 故 $w(t) = ((1-t)/(3/2-t), 0)^\top, w(0) = (2/3, 0)^\top$. 代入同一参考目标，得到超额风险

$$\mathcal{E}(t) = L_0(w(t)) - L_0(w(0)) = \frac{3}{4} \left(\frac{1-t}{3/2-t} - \frac{2}{3} \right)^2 = \frac{t^2}{3(3-2t)^2}. \quad (\text{B.8})$$

它在 $(0, 1)$ 上严格递增，而 $\tau - \rho = \rho(1 - \rho)(k - 1)/(1 - \rho + \rho k)$ ，因此结论成立。 $\square$

该构造说明，当非目标方向同时具有更大的分歧幅度时，原始外积会进一步提高其权重，而归一化可以降低合并风险。 $k = 1$ 持平， $k < 1$ 时同一目标下未归一化严格更好。归一化也有非零污染误差 $\mathcal{E}(\rho)$ ，因此参照目标并未事后定义为归一化解。命题是二次代理中的条件性结果，实际网络中“高分歧是否意味着低价值”需要独立干预检验。

实现与适用范围。 使用 $\varepsilon = 10^{-8}$ 并 detach 分母；实际 $p \rightarrow q$ 时纠正趋零。数学证明要求正概率与精确算术，float32 下溢或 tiny clamp 触发时不直接沿用精确 Fisher 恒等式。学生自信但错误也可能使归一化压低重要纠正：当 $p = (1, 0), q = (\delta, 1 - \delta)$ ，KL 发散而 $\|(p - q)/\sqrt{D + \varepsilon}\|_2 \sim \sqrt{2\delta} \rightarrow 0$ 。此外，自动收缩、有限 CG、非线性传播和选步都会影响最终结果；本附录不提供完整网络准确率的普遍支配保证。