

# INK-Merge: 适配当前网络状态的迭代模型合并

Anonymous authors

Paper under double-blind review

## ABSTRACT

模型合并需要在多个专家的参数约束之间进行折中，但这些约束的功能作用依赖于所在的网络状态。合并改变了层输入、下游传播及尚未解决的预测分歧，在专家或初始状态下建立的统计因而未必适合后续修正。我们提出 INK-Merge：以专家权重为参数锚点，以当前学生的输入和归一化 KL 纠正统计构造双侧加权回归，并在接受更新后重新估计。ViT-B/32 八任务的配对诊断检验统计的状态依赖与重估收益，多起点实验进一步检验适配能力。卡方归一化的几何依据及条件性优势见附录。

## 1 合并约束为什么需要适配当前模型

模型合并将同一预训练模型独立微调得到的专家整合为单一模型。权重平均和任务算术直接组合参数 (Wortsman et al., 2022; Ilharco et al., 2023)，而不同参数方向的功能作用并不相同。Fisher merging 在各专家附近建立后验近似，以 Fisher 衡量参数偏离的代价 (Matena & Raffel, 2022)；RegMean 从匹配输出出发，利用专家层输入统计构造回归问题 (Jin et al., 2023)。MaTS 则将多种合并准则组织为任务子空间中的线性系统 (Tam et al., 2024)。这些方法为如何协调专家约束提供了基础。

本文关注一个进一步的问题：**在专家自身网络中建立的参数约束，放入当前合并网络后，是否仍应获得同样的权重？**一层参数的作用取决于上游送来的输入，以及下游如何将其变化传播到最终预测。合并会同时改变这两方面，也会改变各任务尚未解决的预测分歧。因此，即使某层权重保持不变，其在合并网络中参与修正的条件也可能不同。在专家处测量统计符合专家局部近似的目标，但不能据此保证这些统计始终适合当前学生的后续修正。

我们据此采用如下设计原则：**专家提供参数目标，当前学生提供衡量这些目标的输入统计和纠正统计。**对每个任务，当前激活描述实际访问的输入方向，教师到学生的 KL 反馈描述尚存分歧对应的纠正轴。我们将二者构成的双侧度量用于专家参数的加权回归，以此决定候选模型如何在各任务约束之间折中。

这一原则也引出迭代方式。一次局部代理求解与更新可能尚未消除功能分歧，而被接受的更新又会改变下一次修正的测量条件。因此，我们循环执行“测量当前统计、求解候选、评价并接受更新”，随后在新的学生状态上重估。不同常用起点能否由此得到各自适配的修正，是这一设计需要验证的效果，而非预设的同解收敛性质。第 3 节依次检验统计变化、重估价值和起点适配。

## 2 INK-MERGE：当前统计下的专家参数回归

### 2.1 在当前学生上估计输入与纠正统计

给定  $T$  个固定专家  $\{\theta_t\}_{t=1}^T$ ，以兼容的合并结果初始化共享编码器  $\theta^{(0)}$ ，任务头固定。记专家与当前学生的任务分布为  $p_t(c|x)$ 、 $q_{t,\theta}(c|x)$ 。每任务使用不重叠的无标签统计集  $\mathcal{C}_t$  和留出集  $\mathcal{H}_t$ ；前者收集统计，后者通过任务等权的行为目标

$$\mathcal{L}_{\mathcal{H}}(\theta) = \frac{1}{T} \sum_{t=1}^T \frac{1}{|\mathcal{H}_t|} \sum_{x \in \mathcal{H}_t} D_{\text{KL}}(p_t(\cdot|x) \| q_{t,\theta}(\cdot|x)) \quad (2.1)$$

选择步长与输出轮次。标签不参与选择；默认使用 Iso-C (Marczak et al., 2025) 初始化，其他起点沿用相同修正规则。

对一个样本省略任务与轮次下标。令  $a_{\ell k}, h_{\ell k}$  为线性层  $\ell$  在 token  $k$  的输入与输出,  $z$  为学生 logits,  $J_{\ell k} = \partial z / \partial h_{\ell k}$ 。教师固定时,

$$g_{\ell k} = -\nabla_{h_{\ell k}} D_{\text{KL}}(p||q) = J_{\ell k}^\top (p - q), \quad \delta \ell_{\text{KL}} \approx -\sum_k g_{\ell k}^\top \delta W_\ell a_{\ell k}. \quad (2.2)$$

右式是仅扰动该层权重时的一阶关系, 说明当前输入、下游传播和师生残差共同决定局部功能影响。我们据此在当前学生上测量统计。下文省略 token 下标, 并以

$$D = \chi^2(p||q) = \sum_c \frac{(p_c - q_c)^2}{q_c}, \quad u_\ell = \frac{g_\ell}{\sqrt{D + \varepsilon}}, \quad \tilde{\ell} = \frac{D_{\text{KL}}(p||q)}{\text{stopgrad}(\sqrt{D + \varepsilon})} \quad (2.3)$$

收集归一化纠正。反传  $\tilde{\ell}$  并停止分母梯度得到  $-u_\ell$ , 符号不影响外积。卡方归一化移除额外的样本分歧幅度加权; 它保留纠正轴及层敏感度差异。在正概率和精确算术下,  $u_\ell u_\ell^\top \preceq J_\ell^\top F(q) J_\ell$ , 其中  $F(q) = \text{diag}(q) - qq^\top$ 。相对未归一化的配对消融提高 0.3799 个准确率百分点; 几何证明、优势条件与反例见附录 B。

对任务  $t$  的当前模型  $\theta^{(r)}$ , 在  $\mathcal{C}_t$  上估计

$$A_t^{\ell, (r)} = \mathbb{E}[a_\ell a_\ell^\top], \quad G_t^{\ell, (r)} = \mathbb{E}[u_\ell u_\ell^\top]. \quad (2.4)$$

期望覆盖图像和所收集的 token。 $A$  是当前输入的未中心化二阶矩,  $G$  是当前 KL 纠正的未中心化二阶矩。 $G$  并非普通 Fisher 或真实 KL Hessian; 它保留纠正轴的相对权重, 不保留纠正方向的正负号。

## 2.2 以专家为锚点构造加权回归

设  $W_t^\ell$  为专家权重、 $U$  为候选权重。我们在当前学生输入上比较二者的线性响应, 再沿当前纠正轴投影, 得到平方差  $\mathbb{E}[(u^\top (U - W_t^\ell) a)^2]$ 。借鉴 K-FAC 的因子化形式 (Martens & Grosse, 2015), 以  $A \otimes G$  近似联合二阶矩  $\mathbb{E}[(aa^\top) \otimes (uu^\top)]$ , 便可用两个小矩阵衡量输入与输出方向。

为统一矩阵尺度并稳定求解, 对非零  $d \times d$  矩阵  $M$  使用

$$\mathcal{S}_\lambda(M) = (1 - \lambda) \frac{M}{\text{tr}(M)/d} + \lambda I, \quad \mathcal{S}_\lambda(0) = 0, \quad (2.5)$$

得到实际使用的  $\bar{A}, \bar{G}$ 。本文诊断中输入收缩为 0, 输出收缩由样本统计自动估计。随后近似求解

$$U^{\ell, \star} \approx \arg \min_U \frac{1}{2} \sum_t \left\| (\bar{G}_t^{\ell, (r)})^{1/2} (U - W_t^\ell) (\bar{A}_t^{\ell, (r)})^{1/2} \right\|_F^2. \quad (2.6)$$

专家锚点确定参数目标, 学生统计决定不同偏离方向的权重。这一回归是我们构造的局部代理: 式 (2.2) 解释统计的来源, 却不能严格推出式 (2.6) 是网络 KL 的二阶展开。外积、因子化以及专家到学生的有限位移都引入了近似, 因此候选仍需通过真实留出 KL 检验。

正规方程为

$$\sum_t \bar{G}_t^{\ell, (r)} U^{\ell, \star} \bar{A}_t^{\ell, (r)} = \sum_t \bar{G}_t^{\ell, (r)} W_t^\ell \bar{A}_t^{\ell, (r)}. \quad (2.7)$$

沿用 MaTS 的线性系统求解方式 (Tam et al., 2024), 我们以当前权重为初值, 使用对角预条件 CG, 无需显式构造完整 Kronecker 矩阵。没有有效纠正信号的层保留当前权重。此处的设计在于用当前师生纠正统计构造专家约束, 并在接受更新后重新估计其系数。

## 2.3 接受更新后重新估计

将各层候选组合为  $\theta^\star$ , 记 block 增量  $D_b^{(r)} = W_b^\star - W_b^{(r)}$ 。先选择全局步长, 再依次细化各 block 步长:

$$W_b^{(r+1)} = W_b^{(r)} + \omega_b^{(r)} D_b^{(r)}, \quad \omega_b^{(r)} \in \Omega = \{0, 0.125, 0.25, 0.5, 1\}. \quad (2.8)$$

每次用完整模型的  $\mathcal{L}_{\mathcal{H}}$  评价, 0 允许拒绝更新。接受后,  $a, q, J$  均可能改变, 故下一轮在  $\theta^{(r+1)}$  上重算 A/G; 专家与统计图像保持固定。外层迭代更新测量参照, 内层 CG 求解本轮固定的代理问题。所有 block 拒绝、相对更新低于阈值或达到预算时停止, 返回留出 KL 最低的状态。

**算法 1:** 以当前统计衡量专家约束，并在接受更新后重估。

**输入:** 专家  $\{\theta_t\}$ ; 固定无标签集合  $\{C_t, \mathcal{H}_t\}$ ; 初始化  $\theta^{(0)}$ ; 轮数  $R$

**输出:** 合并模型  $\hat{\theta}$

```

1 缓存专家在  $C_t \cup \mathcal{H}_t$  上的预测;  $\mathcal{Q} \leftarrow \{\theta^{(0)}\}$ 
2 for  $r = 0, \dots, R-1$  do
3   在当前  $\theta^{(r)}$  上收集 A/G, 并按式 (2.5) 处理尺度与收缩
4   从当前权重出发, 以 CG 求解式 (2.7), 得到候选  $\theta^*$ 
5   固定本轮候选, 以留出 KL 选择全局及各 block 步长
6   按式 (2.8) 接受  $\theta^{(r+1)}$ , 加入  $\mathcal{Q}$ ; 满足停止条件则退出
7  $\hat{\theta} \leftarrow \arg \min_{\theta \in \mathcal{Q}} \mathcal{L}_{\mathcal{H}}(\theta)$ 

```




图 1: 状态依赖、重估收益与起点适配。ViT-B/32, 八任务, seed 0。 (a) 相邻学生状态的实际求解度量  $A \otimes G$  的余弦距离, 取层/任务中位数, 对数纵轴。 (b) Average 的完整测试准确率; 刷新与冻结分支共享第一轮模型, 均继续求解和选步, 虚线为单轮 CG400。 (c) 三种常用起点在同一独立诊断集上的准确率。 (a) 比较校准统计, (b)/(c) 使用不同数据分割, 数值不跨面板相减。

### 3 检验设计依据与适配效果

以下在 CLIP ViT-B/32 八任务的归一化 KL-G 路径上, 固定专家、图像与修正规则, 以 seed 0、每轮 CG100、最多四轮进行配对诊断。实验依次检验状态依赖、重估价值和起点适配; 完整协议与对照见附录 A。

**统计是否随网络状态改变?** Average 首轮前后, 实际求解度量的余弦中位数为 0.553, 固定诊断图像上的纠正梯度余弦为 0.248。图 1a 显示前期度量变化明显, 后期趋稳。跨 block 干预进一步固定目标块权重为初始值, 仅将周围网络替换为第一轮状态: Average 的 block 11 纠正梯度余弦仍降至 0.4915。这表明统计变化可以来自周围网络, 不能只根据本块参数是否改变来判断是否需要适配。

**处理这种变化是否有实际价值?** 固定同一个 Average 第一轮 checkpoint, 使用当前与初始统计构造并接受更新, 独立诊断 KL 分别降低 0.080560 与 0.044534。进一步共享第一轮模型后分叉, 四轮刷新与冻结统计的测试准确率为 85.312%、84.519%; 共同第一轮为 83.712%, 单轮 CG400 为 84.565% (图 1b)。这些对照区分继续更新与重估的额外收益。刷新收益依赖状态, RegMean 上仅为 0.003 个百分点; CG400 也不是已收敛或等耗时对照。等幅原始提案和跨 block 的负结果见附录, 现有证据不意味着当前统计在每个方向、每一轮都更好。

**能否适配不同合并起点?** Average/RegMean 的诊断准确率差距由 22.36 缩至 0.15 个百分点 (图 1c), 预测 JS 由 0.13847 降至 0.00412; 终态完整测试仅差 0.24 个百分点, 但逐层相对参数距离中位数仍为 2.53%。这支持功能上的适配, 而不要求参数同解。适配也有边界: Iso-C 与增量范数匹配的未拉平起点在四轮后仍相差 8.25 个测试准确率百分点 (表 1)。

## REFERENCES

- Gabriel Ilharco, Marco Tulio Ribeiro, Mitchell Wortsman, Suchin Gururangan, Ludwig Schmidt, Hannaneh Hajishirzi, and Ali Farhadi. Editing models with task arithmetic. In *International Conference on Learning Representations*, 2023. URL <https://arxiv.org/abs/2212.04089>.
- Xisen Jin, Xiang Ren, Daniel Preotiu-Pietro, and Pengxiang Cheng. Dataless knowledge fusion by merging weights of language models. In *International Conference on Learning Representations*, 2023. URL <https://arxiv.org/abs/2212.09849>.
- Daniel Marczak, Simone Magistri, Sebastian Cygert, Bartłomiej Twardowski, Andrew D. Bagdanov, and Joost van de Weijer. No task left behind: Isotropic model merging with common and task-specific subspaces. In *Proceedings of the 42nd International Conference on Machine Learning*, 2025. URL <https://arxiv.org/abs/2502.04959>.
- James Martens and Roger Grosse. Optimizing neural networks with kronecker-factored approximate curvature. In *Proceedings of the 32nd International Conference on Machine Learning*, volume 37, pp. 2408–2417, 2015. URL <https://proceedings.mlr.press/v37/martens15.html>.
- Michael Matena and Colin Raffel. Merging models with fisher-weighted averaging. In *Advances in Neural Information Processing Systems*, 2022. URL <https://arxiv.org/abs/2111.09832>.
- XuanLong Nguyen, Martin J. Wainwright, and Michael I. Jordan. Estimating divergence functionals and the likelihood ratio by convex risk minimization. *IEEE Transactions on Information Theory*, 56(11):5847–5861, 2010. URL <https://arxiv.org/abs/0809.0853>.
- Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision. In *Proceedings of the 38th International Conference on Machine Learning*, 2021. URL <https://arxiv.org/abs/2103.00020>.
- Derek Tam, Mohit Bansal, and Colin Raffel. Merging by matching models in task parameter subspaces. *Transactions on Machine Learning Research*, 2024. URL <https://arxiv.org/abs/2312.04339>.
- Mitchell Wortsman, Gabriel Ilharco, Samir Yitzhak Gadre, Rebecca Roelofs, Raphael Gontijo-Lopes, Ari S. Morcos, Hongseok Namkoong, Ali Farhadi, Yair Carmon, Simon Kornblith, and Ludwig Schmidt. Model soups: Averaging weights of multiple fine-tuned models improves accuracy without increasing inference time. In *Proceedings of the 39th International Conference on Machine Learning*, 2022. URL <https://arxiv.org/abs/2203.05482>.

## A 动机实验的协议与对照

**共同设置与数据用途。** 所有动机实验使用 CLIP ViT-B/32 (Radford et al., 2021)、八个固定任务专家 (Cars、DTD、EuroSAT、GTSRB、MNIST、RESISC45、SVHN、SUN397) 及 seed 0。每任务统计集包含 256 张图像，另外 256 张不重叠图像用于式 (2.1) 的选步与选轮；每轮 CG100，最多四轮，全部使用原版归一化 KL-G。完整测试只用于报告，不参与更新选择。多起点研究在 validation 的前 256 张图像上诊断，并在其中 64 张记录 block 表征；刷新研究另用固定随机选取的 256 张 validation 图像诊断。因此，两组诊断指标仅在各自配对协议内比较。

**多起点适配及其边界。** 表 1 保留全部四种起点。未拉平对照保持聚合任务增量的奇异值比例，逐原始二维矩阵匹配 Iso-C 的增量 Frobenius 范数；控制覆盖 49 个矩阵，包括拼接 Q/K/V，其余参数沿用 Iso-C。两者终态仍有 8.25 个百分点的测试差距，说明总增量能量不能独自解释可修复性。Average/RegMean 的参数距离采用逐层差异除以预训练层权重范数，再取中位数；其 2.53% 不能解释为全模型欧氏距离。

表 1: 完整四起点对照 (%)。诊断与完整测试属于不同分割；四组均由留出 KL 选中第四轮。

|            | 初始化 | 初始诊断  | 第四轮诊断 | 终态测试  |
|------------|-----|-------|-------|-------|
| Average    |     | 61.28 | 89.50 | 85.31 |
| RegMean    |     | 83.64 | 89.65 | 85.55 |
| Iso-C      |     | 87.74 | 92.92 | 87.06 |
| 未拉平 (范数匹配) |     | 28.86 | 82.18 | 78.80 |

**继续更新与重测统计分别起什么作用？** 对每种初始化先共享第一轮模型  $\theta^{(1)}$ ，再分为刷新和冻结两支。冻结分支固定初始 A/G 及收缩配置，仍然继续求解和选择步长；刷新分支在各自当前模型上重测。两支复用同一批图像。单轮 CG400 从原初始化出发，仅求解一次初始统计问题。表 2 显示，Average 第一轮之后的 1.6004 个百分点收益中，冻结流程也取得 0.8069 个百分点，刷新流程的额外收益为 0.7935 个百分点。

表 2: 完整测试准确率 (%)。最后一列为百分点差；单轮 CG400 不是等耗时或已收敛对照。

|         | 初始化 | 第一轮    | 四轮冻结   | 四轮刷新   | 单轮 CG400 | 刷新 - 冻结 |
|---------|-----|--------|--------|--------|----------|---------|
| Average |     | 83.712 | 84.519 | 85.312 | 84.565   | 0.794   |
| RegMean |     | 85.385 | 85.546 | 85.549 | 85.574   | 0.003   |
| Iso-C   |     | 86.972 | 86.941 | 87.056 | 86.624   | 0.115   |

**统计、方向与接受规则的作用需要区分。** 正文同状态干预保持待更新 checkpoint 一致，但其终态收益包含重测、收缩、有限 CG 和选步的共同作用。将 Average 的原始新旧提案匹配中心化 logit RMS 后， $\theta^{(1)}$  上旧/新方向分别降低独立诊断 KL 0.003379/0.002503， $\theta^{(2)}$  上则为 0.000481/0.002089。因此，当前统计的接受终态更好，不自动意味着原始方向在每个等幅比较中都更好。现有冻结对照也没有单独检验第二轮之后每一轮刷新的必要性。

**周围网络改变，本块也可能需要适配。** 固定目标 block 的全部权重为初始值，其余网络换成第一轮状态。所有比较从同一个混合模型出发，仅允许目标 block 的线性层更新；分别使用初始统计和在混合模型上重测的统计。Average 的 block 11 自身权重未变，输入与纠正梯度余弦却降至 0.8449、0.4915，使用当前统计也获得更大的独立诊断 KL 降低量。图 2 同时保留 block 0 的负结果，支持有条件的网络状态适配。

**归一化的直接消融。** 另一组同机 RTX 4090、seed 0 的配对记录中，归一化与未归一化版本的资产指纹、配置摘要及初始化相同，均刷新四轮并选中第 4 轮；平均测试准确率分别为 87.0451%、86.6652%，最终留出 KL 为 0.155523、0.169934。该消融支持组件有效，但不单独识别卡方相对其他归一化的优势。它与多起点研究的 87.0558% 属于不同运行记录，不拼接为同一轨迹。上述结果均未提供跨 seed 显著性结论。




图 2: 固定本块权重的跨 block 干预。Average, seed 0。每个 block 的两根柱共享同一混合起点, 纵轴为接受更新后的独立诊断 KL 降低量, 越大越好; 不同 block 的起点各不相同。三个 block 为预先选定的 0、5、11。

## B 卡方归一化的依据与优势边界

以下固定一个样本, 设教师  $p$  为概率分布、学生  $q_c > 0$ ,  $e = p - q$ ,  $\mathbf{1}^\top e = 0$ ,  $D = \sum_c e_c^2 / q_c$ 。  $F = \text{diag}(q) - qq^\top$ ,  $J$  为当前学生的 logit Jacobian。所有界均作用于矩阵尺度统一和收缩之前的纠正外积。

### B.1 学生 FISHER 几何下的精确尺度

**命题 B.1** (锐利的 Fisher 相对预算)。对  $e \neq 0$ ,

$$D = \sup_{\text{Var}_q(f) > 0} \frac{(\mathbb{E}_p f - \mathbb{E}_q f)^2}{\text{Var}_q(f)} = e^\top F^\dagger e, \quad ee^\top \preceq dF \iff d \geq D. \quad (\text{B.1})$$

因此, 对  $u = J^\top e / \sqrt{D + \varepsilon}$ ,  $\varepsilon \geq 0$ , 有

$$uu^\top \preceq \frac{D}{D + \varepsilon} J^\top F J \preceq J^\top F J. \quad (\text{B.2})$$

证明. 令  $a_c = p_c / q_c - 1$ , 则  $\mathbb{E}_q a = 0$ ,  $\mathbb{E}_q a^2 = D$ 。对任意  $f$ ,  $\mathbb{E}_p f - \mathbb{E}_q f = \mathbb{E}_q[a(f - \mathbb{E}_q f)]$ 。Cauchy-Schwarz 给出平方差至多为  $D \text{Var}_q(f)$ , 取  $f = a$  达到等号。又有  $F \text{diag}(q)^{-1} e = e$ , 且  $\ker F = \text{span}(\mathbf{1})$ 。任一解与  $F^\dagger e$  仅差常数向量, 左乘  $e^\top$  即得  $e^\top F^\dagger e = D$ 。矩阵不等式等价于对所有  $f$  都有  $(f^\top e)^2 \leq d f^\top F f$ , 其最小  $d$  由刚才的上确界确定。最后除以  $D + \varepsilon$  并作  $J^\top(\cdot)J$  合同变换即可。□

这一结论是经典散度变分框架 (Nguyen et al., 2010) 在当前纠正信号上的具体化。它说明根号卡方是保留 logit 残差方向并满足单位学生 Fisher 预算的最小分母; 原始外积满足同一预算当且仅当  $D \leq 1$ , 这里的 1 是预算尺度, 非精度阈值。若换成其他分母  $\sqrt{s}$ , 同一个全方向保证要求  $s \geq D$ 。例如  $p = (1, 0)$ ,  $q = (\delta, 1 - \delta)$  时,  $D / (2D_{\text{KL}}(p \| q)) \rightarrow \infty$ , 故根号 KL 没有同一全局保证。这不排除它在其他目标上更有效。

### B.2 整体尺度统一后, 改变的是方向权重

将一个图像全部 token 的归一化外积相加, 记为  $Z_i$ 。令  $s_i = D_i + \varepsilon$ ,  $a_i = \text{tr} Z_i$ ,  $P_i = Z_i / a_i$ , 忽略  $a_i = 0$  的项, 且假设总迹非零。归一化与未归一化矩阵的单位迹形式分别为

$$N = \sum_i b_i P_i, \quad R = \sum_i \frac{b_i s_i}{\bar{s}} P_i, \quad b_i = \frac{a_i}{\sum_j a_j}, \quad \bar{s} = \sum_i b_i s_i. \quad (\text{B.3})$$

直接展开可得

$$R - N = \frac{\sum_i b_i (s_i - \bar{s})(P_i - N)}{\bar{s}} = \frac{\text{Cov}_b(s, P)}{\bar{s}}. \quad (\text{B.4})$$

实际的平均对角线统一尺度仅再乘输出维度。因此，归一化的作用不止于改变整体梯度大小，而是移除额外的分歧幅度加权；归一化后的层能量  $a_i$  仍有差异。若所有  $s_i$  或所有  $P_i$  相同，两种形状一致。自动收缩也会随统计变化，故式 (B.4) 只刻画收缩前的直接作用。

### B.3 何时能得到更好的合并解？

几何预算本身不保证更高准确率。下面给出一个保留式 (2.6) 结构的可解析条件：固定两个专家  $w_1 = e_1 = (1, 0)^\top$ ,  $w_2 = 0$ 、输入度量均为 1，第二任务输出度量为  $I/2$ 。第一任务的参考需求为保留  $e_1$  方向；其估计度量中，非目标方向  $e_2$  在归一化后占比为  $0 < \rho < 1$ 。设两类方向的分歧平方幅度比为

$$k = \frac{s_{\text{nuisance}}}{s_{\text{useful}}} > 0, \quad \tau = \frac{\rho k}{1 - \rho + \rho k}. \quad (\text{B.5})$$

则第一任务单位迹度量分别为  $\text{diag}(1 - \rho, \rho)$  与  $\text{diag}(1 - \tau, \tau)$ 。

**命题 B.2** (两专家二次合并的风险边界). 定义

$$L_t(w) = \frac{1}{2}(w - e_1)^\top \text{diag}(1 - t, t)(w - e_1) + \frac{1}{2}w^\top (I/2)w, \quad w(t) = \arg \min_w L_t(w). \quad (\text{B.6})$$

以预先指定的无污染目标  $L_0$  为参照，精确求解且不作输出收缩时，

$$L_0(w(\rho)) < L_0(w(\tau)) \iff k > 1. \quad (\text{B.7})$$

证明. Hessian 为  $\text{diag}(3/2 - t, 1/2 + t) \succ 0$ , 故  $w(t) = ((1-t)/(3/2-t), 0)^\top$ ,  $w(0) = (2/3, 0)^\top$ . 代入同一参考目标，得到超额风险

$$\mathcal{E}(t) = L_0(w(t)) - L_0(w(0)) = \frac{3}{4} \left( \frac{1-t}{3/2-t} - \frac{2}{3} \right)^2 = \frac{t^2}{3(3-2t)^2}. \quad (\text{B.8})$$

它在  $(0, 1)$  上严格递增，而  $\tau - \rho = \rho(1 - \rho)(k - 1)/(1 - \rho + \rho k)$ ，因此结论成立。  $\square$

该构造说明，当非目标方向同时具有更大的分歧幅度时，原始外积会进一步提高其权重，而归一化可以降低合并风险。 $k = 1$  持平， $k < 1$  时同一目标下未归一化严格更好。归一化也有非零污染误差  $\mathcal{E}(\rho)$ ，因此参照目标并未事后定义为归一化解。命题是二次代理中的条件性结果，实际网络中“高分歧是否意味着低价值”需要独立干预检验。

**实现与适用范围。** 使用  $\varepsilon = 10^{-8}$  并 detach 分母；实际  $p \rightarrow q$  时纠正趋零。数学证明要求正概率与精确算术，float32 下溢或 tiny clamp 触发时不直接沿用精确 Fisher 恒等式。学生自信但错误也可能使归一化压低重要纠正：当  $p = (1, 0)$ ,  $q = (\delta, 1 - \delta)$ ，KL 发散而  $\|(p - q)/\sqrt{D + \varepsilon}\|_2 \sim \sqrt{2\delta} \rightarrow 0$ 。此外，自动收缩、有限 CG、非线性传播和选步都会影响最终结果；本附录不提供完整网络准确率的普遍支配保证。