

INK-Merge: 基于当前修正几何的迭代模型合并

Anonymous authors

Paper under double-blind review

ABSTRACT

模型合并需要协调多个专家在共享参数上的功能需求。我们观察到，不同合并起点的功能差距可以经后续修正显著缩小，而每次修正又会改变下一步所依赖的内部统计。这促使我们提出 INK-Merge：在当前合并模型上，以输入激活和归一化教师-学生 KL 纠正信号构造双侧几何，求解逐层加权回归，并在接受更新后重新测量。ViT-B/32 八任务的配对诊断分别支持继续修正、条件性的统计刷新收益，以及对常用合并起点的适配。我们进一步给出卡方归一化的 Fisher 几何依据及其优势条件。

1 从合并起点到当前模型的修正需求

模型合并并将同一预训练模型独立微调得到的专家整合为单一模型。权重平均与任务算术提供了直接的参数组合方式 (Wortsman et al., 2022; Ilharco et al., 2023); Fisher merging、RegMean 及 MaTS 进一步利用任务相关的敏感度或输入统计，区分不同参数方向的作用 (Matena & Raffel, 2022; Jin et al., 2023; Tam et al., 2024)。这些工作自然引出一个后续问题：给定一个已有合并结果，如何依据它当前的功能缺口继续修正？

我们在 CLIP ViT-B/32 八任务设置上，固定专家、无标签校准数据和修正规则，从 Average、RegMean 和 Iso-C (Marczak et al., 2025) 出发进行配对诊断。每轮最多使用 100 步共轭梯度 (CG)，最多执行四轮；以下均为 seed 0 的机制观察，数据划分与额外对照见附录 A。

起点的功能差异可以被修复。 Average 与 RegMean 在同一独立诊断集上的准确率差距由 22.36 缩小到 0.15 个百分点 (图 1a)，预测分布的 JS 散度由 0.13847 降至 0.00412。终态完整测试仅差 0.24 个百分点，而逐层相对参数距离的中位数仍为 2.53%。因此，对起点的适配可以表现为功能接近，无需消除全部参数差异。该现象有明确边界：Iso-C 与增量范数匹配的未拉平起点在四轮后仍相差 8.25 个测试准确率百分点。我们研究的是降低对常用合并起点的敏感性，而非任意初始化的同解收敛。

一次接受更新后，仍有继续修正的空间。 Average 的完整测试准确率从第一轮 83.712% 提高到第四轮的 85.312% (图 1b)。冻结初始统计、继续相同轮数得到 84.519%；将第一次求解延长到 CG400 得到 84.565%。这些对照分别说明，后续更新有用，而继续求解同一个固定统计问题没有复现刷新流程的全部收益。CG400 仅是有限求解预算对照，不代表充分收敛或等耗时比较。

更新改变了下一次修正的工作条件。 一次合并会改变上游输入、当前预测及下游传播，即使专家与图像保持固定， A 和 G 也会变化。Average 首轮前后，固定诊断图像上的纠正梯度余弦中位数为 0.248，实际求解度量的余弦为 0.553 (图 1c)。进一步固定同一个第一轮 checkpoint，使用当前与初始统计构造并接受更新，独立诊断 KL 分别降低 0.080560 与 0.044534。这种同状态干预将统计变化与更新效果联系起来。跨 block 干预还表明，本块权重不变时，周围网络的更新也能改变其统计与修正效果 (附录图 2)。

刷新收益依赖状态：四轮刷新相对冻结的测试增益在 Average、Iso-C、RegMean 上分别为 0.794、0.115、0.003 个百分点；后期度量逐渐稳定。因而，现有证据支持按当前状态重新测量的策略，尚未证明所有起点、所有后续轮次都必须刷新。

从观察到方法。 上述结果指向同一设计原则：以当前合并模型为参照，测量各任务现在允许且需要的修正；接受修正后，再适配新的网络状态。输入二阶矩描述当前访问的方向，教




图 1: 起点适配、继续修正与统计变化。ViT-B/32, 八任务, seed 0。 (a) 三种常用起点在同一独立诊断集上的准确率; 完整四起点对照见表 1。 (b) Average 的完整测试准确率: 刷新与冻结分支共享第一轮模型, 均继续求解和选择步长; 虚线为单轮 CG400。 (c) 相邻学生状态的实际求解度量 $A \otimes G$ 的余弦距离, 取层/任务中位数, 纵轴为对数尺度。 (a) 与 (b) 的数据分割不同, 数值不跨面板相减; (c) 比较校准统计。全部曲线来自已有实测记录。

师-学生 KL 纠正的二阶矩描述尚存分歧所对应的输出轴。将二者与专家参数锚点结合, 得到下一节的迭代合并方法。

2 INK-MERGE: 测量、求解与重新适配

2.1 当前模型上的任务修正

给定 T 个固定专家 $\{\theta_t\}_{t=1}^T$ 及各任务的无标签统计集 $\mathcal{C}_t$ 和留出集 $\mathcal{H}_t$, 以任一兼容合并结果初始化共享编码器 $\theta^{(0)}$ 。任务头固定; 记专家与当前模型在任务 t 上的分布为 $p_t(c|x)$ 、 $q_t^{(r)}(c|x)$ 。用于接受更新的行为目标为

$$\mathcal{L}_{\mathcal{H}}(\theta) = \frac{1}{T} \sum_{t=1}^T \frac{1}{|\mathcal{H}_t|} \sum_{x \in \mathcal{H}_t} D_{\text{KL}}(p_t(\cdot|x) \| q_{t,\theta}(\cdot|x)). \quad (2.1)$$

标签不参与统计、选步或选轮。实验默认使用 Iso-C 初始化; Average 与 RegMean 使用同一后续修正规则。

对一个样本省略任务与轮次下标, 令 z 为学生 logits、 h_ℓ 为某线性层的输出、 $J_\ell = \partial z / \partial h_\ell$ 。教师固定时, 负 KL 梯度为

$$g_\ell = -\nabla_{h_\ell} D_{\text{KL}}(p||q) = J_\ell^\top (p - q), \quad D = \chi^2(p||q) = \sum_c \frac{(p_c - q_c)^2}{q_c}. \quad (2.2)$$

g_ℓ 同时依赖当前师生分歧与当前下游网络。当预测匹配时它为零, 因而表达当前的修正需求。专家处的统计适于近似专家损失或重建专家层输出 (Matena & Raffel, 2022; Jin et al., 2023); 此处要修正的是当前学生, 故用它的输入、残差和 Jacobian 定义度量。我们以

$$u_\ell = \frac{g_\ell}{\sqrt{D + \varepsilon}}, \quad \tilde{\ell} = \frac{D_{\text{KL}}(p||q)}{\text{stopgrad}(\sqrt{D + \varepsilon})} \quad (2.3)$$

收集归一化纠正; 反传 $\tilde{\ell}$ 并对分母停止梯度即可获得 $-u_\ell$, 符号不影响后续外积。

为何使用卡方归一化? 分歧幅度不必等于一个方向应获得的合并权重。令学生 Fisher 为 $F(q) = \text{diag}(q) - qq^\top$, 则 $D = (p - q)^\top F(q)^\dagger (p - q)$, 且

$$u_\ell u_\ell^\top \preceq J_\ell^\top F(q) J_\ell. \quad (2.4)$$

因此, $\sqrt{D}$ 是保留 logit 残差方向、满足单位学生 Fisher 外积预算的最小分母。归一化移除了额外的分歧幅度权重; 它不会消除层敏感度的差异。ViT-B/32 的已有配对消融中, 归一化相对未归一化提高 0.3799 个百分点。附录 B 给出几何证明、条件性优势和反例; 该界并不保证所有任务的准确率都提高。

算法 1: INK-Merge 的外层适配与内层求解。**输入:** 专家 $\{\theta_t\}$; 固定无标签集合 $\{\mathcal{C}_t, \mathcal{H}_t\}$; 初始化 $\theta^{(0)}$; 轮数 R **输出:** 合并模型 $\hat{\theta}$

```

1 缓存专家在  $\mathcal{C}_t \cup \mathcal{H}_t$  上的预测;  $\mathcal{Q} \leftarrow \{\theta^{(0)}\}$ 
2 for  $r = 0, \dots, R-1$  do
3   在当前  $\theta^{(r)}$  上收集  $A_t^{\ell, (r)}, G_t^{\ell, (r)}$  并处理尺度与收缩
4   从当前权重出发, 以 CG 求解各层式 (2.8), 得到  $\theta^*$ 
5   固定本轮提案, 以  $\mathcal{L}_{\mathcal{H}}$  选择全局尺度, 再依次选择各 block 尺度
6   按式 (2.9) 接受  $\theta^{(r+1)}$ , 加入  $\mathcal{Q}$ ; 达到停止条件则退出
7  $\hat{\theta} \leftarrow \arg \min_{\theta \in \mathcal{Q}} \mathcal{L}_{\mathcal{H}}(\theta)$ 

```

2.2 双侧几何与逐层合并

记 $a_\ell^{(r)}(x)$ 为当前模型的实际层输入。我们在 $\mathcal{C}_t$ 上收集未中心化二阶矩

$$A_t^{\ell, (r)} = \mathbb{E}[a_\ell^{(r)} a_\ell^{(r)\top}], \quad G_t^{\ell, (r)} = \mathbb{E}[u_t^{\ell, (r)} u_t^{\ell, (r)\top}]. \quad (2.5)$$

期望覆盖该任务的图像及所收集的 token。 G 是 KL 纠正的二阶矩, 不是普通 Fisher 或真实 KL Hessian。对非零 $d \times d$ 二阶矩 M , 使用

$$\mathcal{S}_\lambda(M) = (1 - \lambda) \frac{M}{\text{tr}(M)/d} + \lambda I, \quad \mathcal{S}_\lambda(0) = 0 \quad (2.6)$$

得到实际求解的 $\bar{A}, \bar{G}$ 。零信号保持为零; 输入收缩在本文诊断中为 0, 输出收缩按样本统计自动估计。

设 W_t^ℓ 为专家权重。以专家为参数锚点, 用当前输入和纠正轴衡量候选差异: $\mathbb{E}[(u^\top(U - W_t^\ell)a)^2]$ 。采用 Kronecker 因子化并处理二阶矩后, 构造代理问题

$$U^{\ell, \star} \approx \arg \min_U \frac{1}{2} \sum_{t=1}^T \left\| (\bar{G}_t^{\ell, (r)})^{1/2} (U - W_t^\ell) (\bar{A}_t^{\ell, (r)})^{1/2} \right\|_F^2. \quad (2.7)$$

其正规方程为

$$\sum_t \bar{G}_t^{\ell, (r)} U^{\ell, \star} \bar{A}_t^{\ell, (r)} = \sum_t \bar{G}_t^{\ell, (r)} W_t^\ell \bar{A}_t^{\ell, (r)}. \quad (2.8)$$

我们以当前权重为初值, 用对角预条件 CG 实现左侧算子, 无需构造完整 Kronecker 矩阵; 没有有效纠正信号的层保留当前权重。这延续了 MaTS 的线性系统求解方式 (Tam et al., 2024), 但系数来自当前学生的纠正统计, 并随接受更新而重估。

式 (2.7) 用专家锚点保留参数目标, 外积刻画修正轴的相对权重。输入与纠正的因子化、有限专家位移及层间耦合使它成为局部代理, 而非真实网络 KL 的精确二阶展开。因此, 求解提案之后仍须用式 (2.1) 判断实际功能效果。

2.3 接受更新后重新统计

将各层提案组合为 θ^* , 以 $D_b^{(r)} = W_b^* - W_b^{(r)}$ 表示 block b 的候选增量。先在全局尺度上选步, 再依次细化各 block 的尺度:

$$W_b^{(r+1)} = W_b^{(r)} + \omega_b^{(r)} D_b^{(r)}, \quad \omega_b^{(r)} \in \Omega = \{0, 0.125, 0.25, 0.5, 1\}. \quad (2.9)$$

每次都评价完整模型的留出 KL, 0 允许拒绝更新。被接受的参数变化会同时改变输入 a 、分布 q 与下游 J , 故下一轮在 $\theta^{(r+1)}$ 上重新计算式 (2.2)–(2.5)。专家和统计图像始终固定, 更新的是测量参照。

算法 1 汇总流程。这里的外层迭代通过“重测、求解、接受”不断适配当前模型, 内层 CG 则求解本轮冻结的代理问题; 两种迭代的作用不同。所有 block 拒绝、相对更新低于阈值或达到预算时停止, 并返回留出 KL 最低的状态。

REFERENCES

- Gabriel Ilharco, Marco Tulio Ribeiro, Mitchell Wortsman, Suchin Gururangan, Ludwig Schmidt, Hannaneh Hajishirzi, and Ali Farhadi. Editing models with task arithmetic. In *International Conference on Learning Representations*, 2023. URL <https://arxiv.org/abs/2212.04089>.
- Xisen Jin, Xiang Ren, Daniel Preotiu-Pietro, and Pengxiang Cheng. Dataless knowledge fusion by merging weights of language models. In *International Conference on Learning Representations*, 2023. URL <https://arxiv.org/abs/2212.09849>.
- Daniel Marczak, Simone Magistri, Sebastian Cygert, Bartłomiej Twardowski, Andrew D. Bagdanov, and Joost van de Weijer. No task left behind: Isotropic model merging with common and task-specific subspaces. In *Proceedings of the 42nd International Conference on Machine Learning*, 2025. URL <https://arxiv.org/abs/2502.04959>.
- Michael Matena and Colin Raffel. Merging models with fisher-weighted averaging. In *Advances in Neural Information Processing Systems*, 2022. URL <https://arxiv.org/abs/2111.09832>.
- XuanLong Nguyen, Martin J. Wainwright, and Michael I. Jordan. Estimating divergence functionals and the likelihood ratio by convex risk minimization. *IEEE Transactions on Information Theory*, 56(11):5847–5861, 2010. URL <https://arxiv.org/abs/0809.0853>.
- Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision. In *Proceedings of the 38th International Conference on Machine Learning*, 2021. URL <https://arxiv.org/abs/2103.00020>.
- Derek Tam, Mohit Bansal, and Colin Raffel. Merging by matching models in task parameter subspaces. *Transactions on Machine Learning Research*, 2024. URL <https://arxiv.org/abs/2312.04339>.
- Mitchell Wortsman, Gabriel Ilharco, Samir Yitzhak Gadre, Rebecca Roelofs, Raphael Gontijo-Lopes, Ari S. Morcos, Hongseok Namkoong, Ali Farhadi, Yair Carmon, Simon Kornblith, and Ludwig Schmidt. Model soups: Averaging weights of multiple fine-tuned models improves accuracy without increasing inference time. In *Proceedings of the 39th International Conference on Machine Learning*, 2022. URL <https://arxiv.org/abs/2203.05482>.

A 动机实验的协议与对照

共同设置与数据用途。 所有动机实验使用 CLIP ViT-B/32 (Radford et al., 2021)、八个固定任务专家 (Cars、DTD、EuroSAT、GTSRB、MNIST、RESISC45、SVHN、SUN397) 及 seed 0。每任务统计集包含 256 张图像，另外 256 张不重叠图像用于式 (2.1) 的选步与选轮；每轮 CG100，最多四轮，全部使用原版归一化 KL-G。完整测试只用于报告，不参与更新选择。多起点研究在 validation 的前 256 张图像上诊断，并在其中 64 张记录 block 表征；刷新研究另用固定随机选取的 256 张 validation 图像诊断。因此，两组诊断指标仅在各自配对协议内比较。

多起点适配及其边界。 表 1 保留全部四种起点。未拉平对照保持聚合任务增量的奇异值比例，逐原始二维矩阵匹配 Iso-C 的增量 Frobenius 范数；控制覆盖 49 个矩阵，包括拼接 Q/K/V，其余参数沿用 Iso-C。两者终态仍有 8.25 个百分点的测试差距，说明总增量能量不能独自解释可修复性。Average/RegMean 的参数距离采用逐层差异除以预训练层权重范数，再取中位数；其 2.53% 不能解释为全模型欧氏距离。

表 1: 完整四起点对照 (%)。诊断与完整测试属于不同分割；四组均由留出 KL 选中第四轮。

	初始化	初始诊断	第四轮诊断	终态测试
Average		61.28	89.50	85.31
RegMean		83.64	89.65	85.55
Iso-C		87.74	92.92	87.06
未拉平 (范数匹配)		28.86	82.18	78.80

继续更新与重测统计分别起什么作用？ 对每种初始化先共享第一轮模型 $\theta^{(1)}$ ，再分为刷新和冻结两支。冻结分支固定初始 A/G 及收缩配置，仍然继续求解和选择步长；刷新分支在各自当前模型上重测。两支复用同一批图像。单轮 CG400 从原初始化出发，仅求解一次初始统计问题。表 2 显示，Average 第一轮之后的 1.6004 个百分点收益中，冻结流程也取得 0.8069 个百分点，刷新流程的额外收益为 0.7935 个百分点。

表 2: 完整测试准确率 (%)。最后一列为百分点差；单轮 CG400 不是等耗时或已收敛对照。

	初始化	第一轮	四轮冻结	四轮刷新	单轮 CG400	刷新 - 冻结
Average		83.712	84.519	85.312	84.565	0.794
RegMean		85.385	85.546	85.549	85.574	0.003
Iso-C		86.972	86.941	87.056	86.624	0.115

统计、方向与接受规则的作用需要区分。 正文同状态干预保持待更新 checkpoint 一致，但其终态收益包含重测、收缩、有限 CG 和选步的共同作用。将 Average 的原始新旧提案匹配中心化 logit RMS 后， $\theta^{(1)}$ 上旧/新方向分别降低独立诊断 KL 0.003379/0.002503， $\theta^{(2)}$ 上则为 0.000481/0.002089。因此，当前统计的接受终态更好，不自动意味着原始方向在每个等幅比较中都更好。现有冻结对照也没有单独检验第二轮之后每一轮刷新的必要性。

周围网络改变，本块也可能需要适配。 固定目标 block 的全部权重为初始值，其余网络换成第一轮状态。所有比较从同一个混合模型出发，仅允许目标 block 的线性层更新；分别使用初始统计和在混合模型上重测的统计。Average 的 block 11 自身权重未变，输入与纠正梯度余弦却降至 0.8449、0.4915，使用当前统计也获得更大的独立诊断 KL 降低量。图 2 同时保留 block 0 的负结果，支持有条件的网络状态适配。

归一化的直接消融。 另一组同机 RTX 4090、seed 0 的配对记录中，归一化与未归一化版本的资产指纹、配置摘要及初始化相同，均刷新四轮并选中第 4 轮；平均测试准确率分别为 87.0451%、86.6652%，最终留出 KL 为 0.155523、0.169934。该消融支持组件有效，但不单独识别卡方相对其他归一化的优势。它与多起点研究的 87.0558% 属于不同运行记录，不拼接为同一轨迹。上述结果均未提供跨 seed 显著性结论。




图 2: 固定本块权重的跨 block 干预。Average, seed 0。每个 block 的两根柱共享同一混合起点，纵轴为接受更新后的独立诊断 KL 降低量，越大越好；不同 block 的起点各不相同。三个 block 为预先选定的 0、5、11。

B 卡方归一化的依据与优势边界

以下固定一个样本，设教师 p 为概率分布、学生 $q_c > 0$, $e = p - q$, $\mathbf{1}^\top e = 0$, $D = \sum_c e_c^2 / q_c$ 。 $F = \text{diag}(q) - qq^\top$, J 为当前学生的 logit Jacobian。所有界均作用于矩阵尺度统一和收缩之前的纠正外积。

B.1 学生 FISHER 几何下的精确尺度

命题 B.1 (锐利的 Fisher 相对预算)。对 $e \neq 0$,

$$D = \sup_{\text{Var}_q(f) > 0} \frac{(\mathbb{E}_p f - \mathbb{E}_q f)^2}{\text{Var}_q(f)} = e^\top F^\dagger e, \quad ee^\top \preceq dF \iff d \geq D. \quad (\text{B.1})$$

因此，对 $u = J^\top e / \sqrt{D + \varepsilon}$, $\varepsilon \geq 0$, 有

$$uu^\top \preceq \frac{D}{D + \varepsilon} J^\top F J \preceq J^\top F J. \quad (\text{B.2})$$

证明. 令 $a_c = p_c / q_c - 1$, 则 $\mathbb{E}_q a = 0$, $\mathbb{E}_q a^2 = D$ 。对任意 f , $\mathbb{E}_p f - \mathbb{E}_q f = \mathbb{E}_q[a(f - \mathbb{E}_q f)]$ 。Cauchy-Schwarz 给出平方差至多为 $D \text{Var}_q(f)$, 取 $f = a$ 达到等号。又有 $F \text{diag}(q)^{-1} e = e$, 且 $\ker F = \text{span}(\mathbf{1})$ 。任一解与 $F^\dagger e$ 仅差常数向量, 左乘 $e^\top$ 即得 $e^\top F^\dagger e = D$ 。矩阵不等式等价于对所有 f 都有 $(f^\top e)^2 \leq d f^\top F f$, 其最小 d 由刚才的上确界确定。最后除以 $D + \varepsilon$ 并作 $J^\top(\cdot)J$ 合同变换即可。□

这一结论是经典散度变分框架 (Nguyen et al., 2010) 在当前纠正信号上的具体化。它说明根号卡方是保留 logit 残差方向并满足单位学生 Fisher 预算的最小分母；原始外积满足同一预算当且仅当 $D \leq 1$, 这里的 1 是预算尺度, 非精度阈值。若换成其他分母 $\sqrt{s}$, 同一个全方向保证要求 $s \geq D$ 。例如 $p = (1, 0)$, $q = (\delta, 1 - \delta)$ 时, $D / (2D_{\text{KL}}(p \| q)) \rightarrow \infty$, 故根号 KL 没有同一全局保证。这不排除它在其他目标上更有效。

B.2 整体尺度统一后, 改变的是方向权重

将一个图像全部 token 的归一化外积相加, 记为 Z_i 。令 $s_i = D_i + \varepsilon$, $a_i = \text{tr} Z_i$, $P_i = Z_i / a_i$, 忽略 $a_i = 0$ 的项, 且假设总迹非零。归一化与未归一化矩阵的单位迹形式分别为

$$N = \sum_i b_i P_i, \quad R = \sum_i \frac{b_i s_i}{\bar{s}} P_i, \quad b_i = \frac{a_i}{\sum_j a_j}, \quad \bar{s} = \sum_i b_i s_i. \quad (\text{B.3})$$

直接展开可得

$$R - N = \frac{\sum_i b_i (s_i - \bar{s})(P_i - N)}{\bar{s}} = \frac{\text{Cov}_b(s, P)}{\bar{s}}. \quad (\text{B.4})$$

实际的平均对角线统一尺度仅再乘输出维度。因此，归一化的作用不止于改变整体梯度大小，而是移除额外的分歧幅度加权；归一化后的层能量 a_i 仍有差异。若所有 s_i 或所有 P_i 相同，两种形状一致。自动收缩也会随统计变化，故式 (B.4) 只刻画收缩前的直接作用。

B.3 何时能得到更好的合并解？

几何预算本身不保证更高准确率。下面给出一个保留式 (2.7) 结构的可解析条件：固定两个专家 $w_1 = e_1 = (1, 0)^\top, w_2 = 0$ 、输入度量均为 1，第二任务输出度量为 $I/2$ 。第一任务的参考需求为保留 e_1 方向；其估计度量中，非目标方向 e_2 在归一化后占比为 $0 < \rho < 1$ 。设两类方向的分歧平方幅度比为

$$k = \frac{s_{\text{nuisance}}}{s_{\text{useful}}} > 0, \quad \tau = \frac{\rho k}{1 - \rho + \rho k}. \quad (\text{B.5})$$

则第一任务单位迹度量分别为 $\text{diag}(1 - \rho, \rho)$ 与 $\text{diag}(1 - \tau, \tau)$ 。

命题 B.2 (两专家二次合并的风险边界). 定义

$$L_t(w) = \frac{1}{2}(w - e_1)^\top \text{diag}(1 - t, t)(w - e_1) + \frac{1}{2}w^\top (I/2)w, \quad w(t) = \arg \min_w L_t(w). \quad (\text{B.6})$$

以预先指定的无污染目标 L_0 为参照，精确求解且不作输出收缩时，

$$L_0(w(\rho)) < L_0(w(\tau)) \iff k > 1. \quad (\text{B.7})$$

证明. Hessian 为 $\text{diag}(3/2 - t, 1/2 + t) \succ 0$, 故 $w(t) = ((1-t)/(3/2-t), 0)^\top, w(0) = (2/3, 0)^\top$. 代入同一参考目标，得到超额风险

$$\mathcal{E}(t) = L_0(w(t)) - L_0(w(0)) = \frac{3}{4} \left(\frac{1-t}{3/2-t} - \frac{2}{3} \right)^2 = \frac{t^2}{3(3-2t)^2}. \quad (\text{B.8})$$

它在 $(0, 1)$ 上严格递增，而 $\tau - \rho = \rho(1 - \rho)(k - 1)/(1 - \rho + \rho k)$ ，因此结论成立。 $\square$

该构造说明，当非目标方向同时具有更大的分歧幅度时，原始外积会进一步提高其权重，而归一化可以降低合并风险。 $k = 1$ 持平， $k < 1$ 时同一目标下未归一化严格更好。归一化也有非零污染误差 $\mathcal{E}(\rho)$ ，因此参照目标并未事后定义为归一化解。命题是二次代理中的条件性结果，实际网络中“高分歧是否意味着低价值”需要独立干预检验。

实现与适用范围。 使用 $\varepsilon = 10^{-8}$ 并 detach 分母；实际 $p \rightarrow q$ 时纠正趋零。数学证明要求正概率与精确算术，float32 下溢或 tiny clamp 触发时不直接沿用精确 Fisher 恒等式。学生自信但错误也可能使归一化压低重要纠正：当 $p = (1, 0), q = (\delta, 1 - \delta)$ ，KL 发散而 $\|(p - q)/\sqrt{D + \varepsilon}\|_2 \sim \sqrt{2\delta} \rightarrow 0$ 。此外，自动收缩、有限 CG、非线性传播和选步都会影响最终结果；本附录不提供完整网络准确率的普遍支配保证。